

# Capitolul 3

## Metode de ordinul I

### 3.1 Preliminarii

În acest capitol abordăm probleme neliniare de optimizare neconstrânsă (*unconstrained nonlinear programming* - UNLP):

$$(UNLP) : \min_{x \in \mathbb{R}^n} f(x), \quad (3.1)$$

unde funcția obiectiv  $f$  este de două ori diferențiabilă. Conform condițiilor de optimalitate necesare pentru problema (3.1), orice punct de minim local pentru problema (UNLP),  $x^*$ , satisface următoarele relații:

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succcurlyeq 0.$$

În plus, dacă pentru un punct  $y^* \in \text{dom} f$  avem  $\nabla f(y^*) = 0$  și  $\nabla^2 f(y^*) \succ 0$ , atunci  $y^*$  este punct de minim local strict pentru problema (UNLP) dată în (3.1).

Condițiile de optimalitate joacă un rol fundamental în dezvoltarea algoritmilor eficienți din domeniul optimizării (vezi [1, 2]). În particular, condițiile de ordinul I stau la baza unei clase relativ largi de metode de ordin I (metode ce folosesc evaluarea funcției și informație de gradient). În cazul convex, găsirea unui punct ce satisface condițiile de optimalitate necesare este echivalentă cu rezolvarea problemei de optimizare originale (deoarece condițiile de ordinul I sunt suficiente). Acest argument furnizează o imagine clară asupra facilităților *optimizării convexe* față de cazurile neconvexe, unde pentru găsirea unui punct minim/maxim *local* este necesară rezolvarea condițiilor de ordinul I și de ordin II. Așa cum se observă din experimentele numerice, deși algoritmi de ordinul

I prezintă o complexitate a iterației foarte scăzută (în comparație cu cei de ordin II) și o convergență accelerată în regiunile îndepărtate de punctul de optim, atunci când algoritmul intră în vecinătatea punctului de optim, viteza acestora scade considerabil. De aceea, găsirea unui punct de optim cu o acuratețe mare este un proces dificil pentru metodele de ordin I. În cazul problemelor de dimensiuni foarte mari, când nu este necesară aflarea punctului de optim cu o acuratețe ridicată, recomandarea principală pentru rezolvarea acestora sunt algoritmi de ordin I datorită complexității reduse a iterațiilor acestora. În continuare, prezentăm principalele metode de ordin I și exemple de funcționare ale acestora.

## 3.2 Probleme rezolvate de laborator

### 3.2.1 Metoda Gradient

Metoda gradient se află printre primele și cele mai simple metode dezvoltate în scopul determinării unui punct critic aflat pe o anumită curbă (Cauchy, 1847). În principiu, metoda gradient reprezintă un algoritm de ordin I care generează un șir de puncte (vectori)  $x_1, x_2, \dots$ , pornind dintr-un punct inițial ales. Structura esențială a metodei gradient este enunțată în continuare:

#### Metoda Gradient

1. Se alege punctul inițial  $x_0$ ,  $k := 0$ .
2. Se determină pasul  $\alpha_k$  și se actualizează  $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$ .
3. Dacă criteriul de oprire nu este satisfăcut, atunci se incrementează  $k := k + 1$  și se reia pasul 2,

unde  $\nabla f(x)$  reprezintă gradientul funcției  $f$  în punctul  $x$ . Pentru alegerea pasului  $\alpha_k$  avem mai multe opțiuni:

(i) Alegerea ideală a pasului  $\alpha_k$  la fiecare iterație presupune ca funcția scalară  $\phi(\alpha) = f(x_k - \alpha \nabla f(x_k))$  să descrească cât mai mult posibil, i.e:

$$\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha),$$

numită și problema de "line search".

(ii) Deseori, în funcție de  $f$ , minimizarea lui  $\phi(\alpha)$  poate fi foarte dificilă. În acest caz,  $\alpha_k$  poate fi găsit prin diverși algoritmi mai simpli de

căutare, ce includ condiții necesare asupra pasului pentru asigurarea unei descreșteri suficiente a funcției. Condițiile Wolfe reprezintă un exemplu elocvent pentru această strategie de "line-search":

1. Se aleg două constante  $c_1$  și  $c_2$  ce satisfac  $0 < c_1 < c_2 < 1$
2. Se determină  $\alpha_k > 0$  astfel încât:

$$f(x_k - \alpha_k \nabla f(x_k)) \leq f(x_k) - c_1 \alpha_k \nabla f(x_k)^T \nabla f(x_k) \quad (3.2)$$

$$\nabla f(x_k)^T \nabla f(x_k - \alpha_k \nabla f(x_k)) \leq c_2 \nabla f(x_k)^T \nabla f(x_k). \quad (3.3)$$

(iii) Un caz particular des utilizat în practică este "metoda backtracking" ce ajustează dimensiunea pasului  $\alpha_k$  pentru ca prima relație Wolfe (3.2) să fie satisfăcută; metoda presupune alegerea unui parametru  $\rho \in (0, 1]$  și actualizarea dimensiunii pasului, după cum urmează:

1. Se alege  $\alpha_0 > 0, \rho \in (0, 1]$ ;
2. Cât timp  $\alpha_k$  nu satisface prima condiție Wolfe (3.2) iterăm :
  - 2.1.  $\alpha_{k+1} = \rho \alpha_k; k = k + 1$ .

(iv) Pentru funcțiile cu gradient continuu în sens Lipschitz cu o constantă  $L > 0$ , putem alege pasul  $\alpha_k$  constant la fiecare iterație. Dacă aplicăm iterația metodei gradient, din condiția continuității funcțiilor cu gradient Lipschitz avem:

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \left(1 - \frac{L}{2} \alpha_k\right) \|\nabla f(x_k)\|^2,$$

rezultând că trebuie să selectăm  $\alpha_k \in (0, \frac{2}{L})$ , iar pentru o descreștere optimă a funcției, la fiecare iterație alegem  $\alpha_k = \frac{1}{L}$ .

În exemplul următor vom implementa metoda gradient pentru prima și a treia dintre opțiunile alegerii pasului  $\alpha_k$ , unde criteriul de oprire va fi impus de scăderea termenului  $\|\nabla f(x_k)\|$  sub o precizie dată.

**Exemplul 15.** Fie funcția  $f(x) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$ . Să se implementeze metoda gradient pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^n} f(x), \quad (3.4)$$

în varianta cu pas ideal și cea cu pas ales prin metoda de backtracking.

*Rezolvare.* Pentru început, vom avea nevoie de două funcții:

```
f=feval_obj(x), g=gradient_obj(x)
```

care să returneze valoarea funcției într-un punct  $x$ , respectiv gradientul funcției în acel punct. Din moment ce vom căuta pasul ideal la fiecare iterație a metodei gradient, va fi necesară o funcție ce returnează valoarea funcției  $\phi(\alpha) = f(x + \alpha d)$ :

```
function f=phi_obj(alpha,x,d)
    f=feval_obj(x+alpha*d);
end
```

Pentru găsirea pasului ideal la fiecare iterație, vom utiliza funcția `fminsearch`. Vom porni de la un punct inițial  $x_0$ , iar condiția de oprire a algoritmului va presupune ca norma gradientului să fie sub o anumită toleranță impusă `eps`. Implementarea algoritmului este dată de următoarea secvență de cod:

```
function xmin=gradient_method(x0,eps)
% Initializam vectori/matrice pentru
% memorarea gradientilor, a punctelor x
% generate de algoritm, etc
puncte_gradient=[]; puncte_iteratie=[];
valori_functie=[]; norme_gradienti=[];
%vom utiliza un vector g pentru a stoca gradientul curent
x=x0; g=gradient_obj(x);
while(norm(g)>eps)
    g=gradient_obj(x); puncte_gradient=[puncte_gradient g];
    puncte_iteratie=[puncte_iteratie x];
    valori_functie=[valori_functie; feval_obj(x)];
    norme_gradienti=[norme_gradienti; norm(g)];
    alpha=fminsearch(@(alpha) phi_obj(alpha,x,-g).1);
    x=x-alpha*g
end
xmin=x;


%Pentru afisarea grafica a rezultatelor,
%avem urmatoarele instructiuni
t=1:length(valori_functie);
figure(1)
hold on
```

```

plot(t,norme_gradienti(t),'k','LineWidth',2);
hold off
figure(2)
hold on
plot(t,valori_functie(t),'k','LineWidth',2);
hold off

%Pentru trasarea liniilor de contur si evolutia
%metodei gradient, avem urmatoarele
%instructiuni
[x1,x2]=meshgrid([1.2:0.01:2.8],[0.4:0.01:1.6]);
z=(x1-2).^4+(x1-2.*x2).^2;
figure(3)
hold on
contour(x1,x2,z,valori_functie);
plot3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valori_functie,'r');
scatter3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valori_functie,'filled');
hold off

```



**Figura 3.1:** Convergența metodei gradient cu pas ideal.

Apelarea funcției precedente se face în linia de comandă din Matlab, e.g.:

```
xmin=gradient_method([1.4;0.5],0.0001)
```

Pentru varianta metodei gradient cu pasul determinat de metoda de backtracking, se poate înlocui în cod funcția `fminsearch` cu următoarea secvență de cod:


```

function alpha=backtrack_alpha(x,d)
    alpha=1; t1=0.9; t2=0.2;
    g=gradient_obj(x);
    %Va trebui satisfacuta conditia Armijo:
    while(feval_obj(x+alpha*d)>feval_obj(x)+t1*alpha*g'*d)
        alpha=alpha*t2;
    end

```

care va fi apelată cu  $d = -g = -\nabla f(x)$ .

În Fig. 3.1 se observă caracteristica elocventă a metodei gradient care a fost precizată în secțiunile anterioare, și anume decelerarea ratei de convergență pe măsură ce algoritmul se apropie de punctul de optim. În plus, Fig. 3.2 redă rezultatele grafice comparative ale convergenței metodei gradient când criteriul de oprire este de forma  $f(x_k) - f^*$  sau  $\|\nabla f(x_k)\|$ . Observăm că deși criteriul  $f(x_k) - f^*$  reflectă mult mai bine acuratețea punctului curent, acesta este rar folosit în practică, deoarece valoarea optimă nu se cunoaște a priori.




**Figura 3.2:** *Comparația convergenței variantelor metodei gradient (cu criteriul  $f(x_k) - f^*$  în prima figură și cu criteriul  $\|\nabla f(x_k)\|$  în a doua), pentru pas ideal (linie continuă) și pas obținut prin backtracking (linie punctată).*

În exemplul următor, vom implementa metoda gradient cu pas constant pentru o funcție pătratică cu gradient Lipschitz, pentru care  $L = \lambda_{\max}(Q)$ .

**Exemplul 16.** Fie funcția pătratică:

$$f(x) = \frac{1}{2}x^T \begin{bmatrix} 2.04 & -2.8 & 3.3; \\ -2.8 & 6 & -4 \\ 3.3 & -4 & 17.25 \end{bmatrix} x + [1 \quad -1 \quad -2]x$$



**Figura 3.3:** Progresul metodei gradient pornind dintr-un punct inițial ales aleatoriu, spre punctul de optim.

Să se implementeze metoda gradient pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^3} f(x).$$

*Rezolvare.* Implementarea metodei gradient din cerința precedentă este dată de următoarea secvență de cod:

```
function [x,f,iter]=gradient(eps)
Q=[2.04    -2.8    3.3;...
   -2.8     6    -4;...
    3.3    -4   17.25];
q=[1;-1;-2];

L=max(eig(Q)); x=rand(3,1);
grad=Q*x+q;
f_new=0.5*x'*Q*x+q'*x; f_old=f_new+1; iter=0;

while ((f_old-f_new)>eps)
f_old=f_new; x=x-(1/L)*grad;
grad=Q*x+q; f_new=0.5*x'*Q*x+q'*x;
iter=iter+1;
end
f=f_new;
end
```

Să se rezolve sistemul  $Qx = -q$  și să se compare soluția acestuia cu cea a problemei anterioare. Să se comenteze observațiile făcute.

### 3.2.2 Metoda gradientilor conjugați

Metoda gradientilor conjugați face parte, de asemenea, din clasa metodelor de optimizare de ordinul I și reprezintă o metodă iterativă cu perfor-

manțe deosebite în rezolvarea problemelor pătratice. A fost dezvoltată de către Hestenes și Stiefel în 1951, în scopul rezolvării sistemelor de ecuații liniare de mari dimensiuni. Deoarece orice problemă de rezolvare a unui sistem de ecuații liniare/nelineare se poate transforma într-o problemă de optimizare pătratică, metoda gradientilor conjugați este considerată o metodă de optimizare. Vom observa că iterația are aproximativ aceeași complexitate ca și cea a metodei gradient, însă folosește un alt raționament pentru a converge la punctul de optim.

#### Metoda gradientilor conjugați

1. Se alege  $\alpha_0 > 0$ ,  $x_0$  și se calculează  $d_0 = -\nabla f(x_0)$ .
2. Se actualizează șirurile  $x_{k+1} = x_k + \alpha_k d_k$  și  $d_{k+1} = -r_{k+1} + \beta_k d_k$ .
3. Dacă criteriul de oprire nu este satisfăcut, atunci se incrementează  $k = k + 1$  și se reia pasul 2,

unde  $\nabla f(x)$  reprezintă gradientul funcției  $f$  în punctul  $x$ , iar  $r_k = \nabla f(x_k)$ . Parametrii  $\alpha_k$  și  $\beta_k$  sunt definitorii pentru metoda direcțiilor conjugate, variantele de alegere a acestora reprezentând elemente fundamentale ale dezvoltării de noi metode de direcții (gradienti) conjugate (conjugați). Cea mai des folosită variantă a metodei de direcții conjugate pentru funcții pătratice este dată de

$$\alpha_k = -\frac{r_k^T d_k}{d_k^T \nabla^2 f(x_k) d_k}, \quad \beta_k = \frac{r_{k+1}^T \nabla^2 f(x_k) d_k}{d_k^T \nabla^2 f(x_k) d_k}$$

**Exemplul 17.** Să se determine punctul de optim și valoarea optimă a funcției pătratice  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  definită de:

$$f(x) = 4.5x_1^2 + 5x_2^2 + 3x_1x_2 - 2x_1 - x_2,$$

utilizând metoda gradientilor conjugați cu punctul inițial  $x_0 = [0 \ 0]^T$ .

*Rezolvare.* Rescriem funcția  $f$  în formă matriceală:

$$f(x) = \frac{1}{2}x^T Qx + q^T x,$$



unde  $Q = \begin{bmatrix} 9 & 3 \\ 3 & 10 \end{bmatrix}$ ,  $q^T = [-2 \ -1]$ . Cunoaștem că pentru a rezolva probleme pătratice de dimensiune  $n$  cu ajutorul metodei gradientilor conjugați sunt necesare  $n$  iterații ale acestei metode. De aceea, problema din enunț poate fi rezolvată în două iterații de această metodă. Având la dispoziție gradientul  $\nabla f(x_0)$  și direcția  $d_0$ , putem calcula:

$$\alpha_0 = -\frac{\nabla f(x_0)^T d_0}{d_0^T Q d_0}.$$

Prima iterație din șirul  $x_k$  al metodei de gradienti conjugați se calculează pe baza informației acumulate până în momentul  $k = 1$ :

$$x_1 = x_0 + \alpha_0 d_0.$$

La a doua și ultima iterație, pentru calculul lui  $x_2$  avem nevoie de direcția  $d_1 = -\nabla f(x_1) + \beta_0 d_0$ , unde  $\beta_0 = \frac{\nabla f(x_1)^T Q d_0}{d_0^T Q d_0}$ . În final, pentru calculul lui  $x_2$  este necesar parametrul  $\alpha_1 = -\frac{\nabla f(x_1)^T d_1}{d_1^T Q d_1}$  și rezultă:

$$x_2 = x_1 - \alpha_1 d_1.$$

Deoarece metoda gradientilor conjugați are nevoie de două iterații în cazul nostru, iterația  $x_2$  reprezintă soluția problemei de minimizare. Știind că soluția problemei satisface, de asemenea, și sistemul liniar de ordin II:

$$Qx + q = 0,$$

obținem și un criteriu de verificare pentru soluția returnată de algoritmul de gradienti conjugați. O implementare în cod Matlab este dată de următoarea secvență:

```
function [x f]=conjugate()
Q=[9 3;3 10]; q=[-2;-1];
x=[0;0]; f_new=0.5*x'*Q*x+q'*x;
f=f_new+1; grad=Q*x+q;

iter=0; d=-grad;
while (iter<2)
f=f_new; alpha=-(grad'*d)/(d'*Q*d);
x=x+alpha*d; grad=Q*x+q;
beta=(grad'*Q*d)/(d'*Q*d);
```

```

d=-grad+beta*d; f_new=0.5*x'*Q*x+q'*x;
iter=iter+1;
end
f=f_new;
end

```

Experimentele numerice au condus la concluzia că pentru o funcție pătratică convexă  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ , metoda gradientilor conjugați converge în  $n$  iterații. Observăm un comportament deosebit al acestei metode, deoarece în general, majoritatea metodelor cunoscute converg într-un număr infinit de iterații.

### 3.3 Probleme rezolvate de seminar

#### 3.3.1 Aproximări pătratice

**Problema 1.** Fie funcția  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ,  $f(x) = \frac{1}{2}(x_1^2 + x_2^2)e^{(x_1^2 - x_2^2)}$ .

- (i) Să se verifice că punctul  $x^* = [0 \ 0]^T$  este un punct de minim local.
- (ii) Să se evalueze gradientul și Hessiana în punctul  $x_0 = [1 \ 1]^T$  și să se verifice că Hessiana nu este pozitiv definită. Să se arate că  $\nu = 3$  este valoarea întreagă minimă pentru care  $H = \nabla^2 f(x_0) + \nu I \succ 0$ .
- (iii) Fie punctul  $x_0 = [1/2 \ 0]^T$ . Să se scrie aproximarea pătratică uzuală (serie Taylor) a acestei funcții în jurul lui  $x_0$  și o aproximare pătratică utilizând în locul Hessiane o matrice  $\frac{1}{\beta}I$ , cu  $\beta > 0$ . Minimizați ambele aproximări.

*Rezolvare.* (i) Gradientul și Hessiana funcției vor fi:

$$\nabla f(x) = e^{(x_1^2 - x_2^2)} \begin{bmatrix} x_1^3 + x_1(1 + x_2^2) \\ -x_2^3 + x_2(1 - x_1^2) \end{bmatrix}$$

$$\nabla^2 f(x) = e^{(x_1^2 - x_2^2)} \begin{bmatrix} 2x_1^4 + x_1^2(5 + 2x_2^2) + x_2^2 + 1 & -2x_1x_2(x_1^2 + x_2^2) \\ -2x_1x_2(x_1^2 + x_2^2) & 2x_2^4 + x_2^2(2x_1^2 - 5) - x_1^2 + 1 \end{bmatrix}.$$

Evident, pentru  $x^* = 0$  este punct de minim local deoarece satisface condițiile suficiente de optimalitate:

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) = I_2 \succ 0.$$

(ii) Pentru  $x_0 = [1 \ 1]^T$  avem:

$$\nabla f(x_0) = \begin{bmatrix} 3 \\ -1 \end{bmatrix}, \quad \nabla^2 f(x_0) = \begin{bmatrix} 12 & -4 \\ -4 & -1 \end{bmatrix},$$

de unde rezultă că valorile proprii ale lui  $\nabla^2 f(x_0)$  sunt  $\lambda_{1,2} = \frac{11 \pm \sqrt{233}}{2} \approx (13.13, -2.13)$ , i.e. matricea nu este pozitiv definită. Mai mult, observăm că  $(\nabla^2 f(x_0) + \nu I) \succ 0$  pentru  $\nu = 3 > \lambda_2 \approx -2.13$ .

(iii) Pentru punctul  $x_0 = [1/2 \ 0]^T$  vom avea:

$$\nabla f(x_0) = e^{\frac{1}{4}} \begin{bmatrix} \frac{5}{8} \\ 0 \end{bmatrix}, \quad \nabla^2 f(x_0) = e^{\frac{1}{4}} \begin{bmatrix} \frac{19}{8} & 0 \\ 0 & \frac{3}{4} \end{bmatrix}.$$

Aproximarea în serie Taylor a funcției în jurul punctului  $x_0 = [1/2 \ 0]^T$  va fi:

$$\begin{aligned} f(x) &\approx f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0) \\ &= e^{\frac{1}{4}} \left( \frac{19}{16} x_1^2 + \frac{3}{4} x_2^2 - \frac{9}{16} x_1 + \frac{9}{64} \right), \end{aligned}$$

al cărei punct de minim este dat de  $x_1^N = [9/38 \ 0]^T$ . Aproximarea cu  $\frac{1}{\beta} I$  are următoarea formă:

$$f(x) \approx f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \frac{1}{\beta} I_2 (x - x_0)$$

care în acest caz este dată de:

$$\begin{aligned} f(x) &\approx \frac{1}{8} e^{\frac{1}{4}} + e^{\frac{1}{4}} \begin{bmatrix} \frac{5}{8} & 0 \end{bmatrix} \begin{bmatrix} x_1 - \frac{1}{2} \\ x_2 \end{bmatrix} + \frac{1}{2\beta} \begin{bmatrix} x_1 - \frac{1}{2} & x_2 \end{bmatrix}^T I_2 \begin{bmatrix} x_1 - \frac{1}{2} \\ x_2 \end{bmatrix} \\ &= \frac{1}{8} e^{\frac{1}{4}} + \frac{1}{2\beta} \left( (x_1 - \frac{1}{2})^2 + x_2^2 \right) + \frac{5}{8} e^{\frac{1}{4}} \left( x_1 - \frac{1}{2} \right), \end{aligned}$$

de unde rezultă punctul de minim  $x_1^G = [-\frac{5\beta}{8} e^{\frac{1}{4}} + \frac{1}{2} \ 0]^T$ . Observăm că putem alege  $\beta = \frac{8}{19e^{\frac{1}{4}}}$  astfel încât  $x_1^G = x_1^N$ , iar  $f(x_1^N) = f(x_1^G)$ . În cazul general însă, obținem puncte  $x_1^G$  și  $x_1^N$  pentru care  $f(x_1^G) > f(x_1^N)$ .

### 3.3.2 Condiții de optimalitate de ordin I

**Problema 2.** Rezolvați problema de maximizare:

$$\max_{x,y} f(x,y) = \frac{1}{(x-a)^2 + (y-a)^2 + 1}.$$

Să se discute rezultatul în funcție de  $a$ .

*Rezolvare.* Prin aplicarea condițiilor suficiente de ordin I, i.e.  $\nabla f(x, y) = 0$ , obținem sistemul:

$$\begin{cases} \frac{\partial f}{\partial x} = 0 \\ \frac{\partial f}{\partial y} = 0 \end{cases}$$

Explicitând cele două ecuații, obținem:

$$\begin{cases} x - a = 0 \\ y - a = 0. \end{cases}$$

În concluzie, există un singur punct critic dat de perechea  $(a, a)$ . Mai departe, demonstrăm că punctul critic este punct de maxim. Verificăm condițiile suficiente de ordin II, i.e. Hessiana  $\nabla^2 f(x)$  în punctul  $(a, a)$  este o matrice negativ definită,

$$\nabla^2 f(a, a) = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}.$$

și constatăm că punctul  $(a, a)$  este punct de maxim, indiferent de valoarea parametrului  $a$ .

**Problema 3.** Fie funcția  $f(x_1, x_2) = 11x_1^2 + 20x_1x_2 + \alpha x_2^2 - 2x_1 - 2x_2 + 2$ .

- (i) Să se discute care sunt punctele de minim locale în funcție de  $\alpha$ .
- (ii) Pentru ce valori ale lui  $\alpha$ , funcția are valoarea minimă egală cu 2?

*Rezolvare.* (i) Observăm că  $f(x_1, x_2)$  este funcție pătratică:

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2}x^T Qx + q^T x + r \\ &= \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 22 & 20 \\ 20 & 2\alpha \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} -2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 2, \end{aligned}$$

unde  $Q = \begin{bmatrix} 22 & 20 \\ 20 & 2\alpha \end{bmatrix}$ ,  $q = \begin{bmatrix} -2 \\ 2 \end{bmatrix}^T$ ,  $r = 2$ . Punctele staționare ale funcției  $f$  sunt soluții ale sistemului:

$$\nabla f(x_1, x_2) = Qx + q = \begin{bmatrix} 22x_1 + 20x_2 - 2 \\ 20x_1 + 2\alpha x_2 - 2 \end{bmatrix} = 0. \quad (3.5)$$

Un factor ce determină natura punctelor staționare este convexitatea funcției  $f$ . Una din modalitățile de verificare a proprietății de convexitate

presupune  $\nabla^2 f(x) = Q \succeq 0$ , pentru orice  $x \in \text{dom} f$ . Valorile proprii ale matricei  $Q$  sunt rădăcinile polinomului caracteristic  $\lambda^2 - \lambda(22 + 2\alpha) + 44\alpha + 400 = 0$ . Astfel, discutăm convexitatea funcției  $f$  după  $\alpha$ :

Dacă  $\alpha > \frac{100}{11}$ , funcția  $f$  este convexă și orice soluție a sistemului (3.5) este un punct de minim global. Rezolvând sistemul, obținem  $x_1^* = \frac{-1}{11\alpha-100}(10-\alpha)$ ,  $x_2^* = \frac{1}{11\alpha-100}$

Dacă  $\alpha = \frac{100}{11}$  sistemul (3.5) nu are soluție și este definit de ecuațiile:

$$\begin{aligned} 20x_1 + \frac{200}{11}x_2 - 2 &= 0, \\ 22x_1 + 20x_2 - 2 &= 0 \end{aligned}$$

În acest caz,  $f$  este convexă, dar nu există punct de minim, i.e.  $q \notin \text{Im}(Q)$ .

Dacă  $\alpha < \frac{100}{11}$ , funcția  $f$  nu este convexă deoarece matricea  $Q$  este indefinită. Punctul critic obținut în acest caz din rezolvarea sistemului (3.5) este punct de inflexiune (staționar).

(ii) Impunem condiția ca punctul  $(x^*, y^*)$  să fie punct critic, i.e.

$$\nabla f(x_1, x_2) = 0 \Leftrightarrow \begin{cases} x_1^* = \frac{-1}{11\alpha-100}(10-\alpha) \\ x_2^* = \frac{1}{11\alpha-100}. \end{cases}$$

Pentru a determina un punct de minim, ținem cont de condiția de la punctul precedent  $\alpha > \frac{100}{11}$ . Înlocuind valorile lui  $x_1^*$ , respectiv  $x_2^*$  în

$$f\left(\frac{\alpha-10}{11\alpha-100}, \frac{1}{11\alpha-100}\right) = 2,$$

se determină ușor valoarea scalarului  $\alpha$ .

### 3.3.3 Metoda gradient

**Problema 4.** Fie funcția  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ,  $f(x) = \frac{1}{2}\|Ax - b\|_2^2 + 2x^T x$ , unde  $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$  și  $b = [0 \ 1]^T$ . Considerăm de asemenea problema de optimizare aferentă:  $\min_{x \in \mathbb{R}^2} f(x)$ .

- (i) Să se scrie problema de optimizare aferentă ca o problemă QP. Să se calculeze expresia gradientului și Hessienei funcției obiectiv. Să se demonstreze că funcția obiectiv este convexă.

- (ii) Să se calculeze punctul de minim global  $x^*$ . Pornind din punctul inițial  $x_0 = [0 \ 1]^T$ , să se implementeze prima iterație  $x_1$  a metodei gradient cu pasul  $\alpha_0 = 1$ . Să se compare  $f(x_0)$ ,  $f(x_1)$  și  $f(x^*)$  și să se discute concluzia.

*Rezolvare.* (i) Pentru a scrie problema anterioară ca o problemă QP, explicităm mai întâi norma din cadrul funcției obiectiv:

$$\begin{aligned} \frac{1}{2} \|Ax - b\|_2^2 &= \frac{1}{2} (Ax - b)^T (Ax - b) \\ &= \frac{1}{2} (x^T A^T Ax - x^T A^T b - b^T Ax + b^T b) \\ &= \frac{1}{2} x^T A^T Ax - (A^T b)^T x + \frac{b^T b}{2} \end{aligned}$$

Formulând  $2x^T x$  ca  $\frac{1}{2}x^T 4I_2 x$  avem:

$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^T Q x + q^T x + c$$

unde  $Q = A^T A + 4I_2$ ,  $q = -A^T b$  și  $c = \frac{1}{2} b^T b$ . Se pot determina ușor parametrii:

$$Q = \begin{bmatrix} 6 & 2 \\ 2 & 6 \end{bmatrix}, \quad q = \begin{bmatrix} -1 \\ -1 \end{bmatrix}.$$

Deoarece  $Q$  este simetrică, expresia gradientului și a Hessienei sunt definite de:

$$\nabla f(x) = Qx + q = \begin{bmatrix} 6x_1 + 2x_2 - 1 \\ 2x_1 + 6x_2 - 1 \end{bmatrix} \quad \text{și} \quad \nabla^2 f(x) = Q$$

Funcția  $f$  este de două ori diferențiabilă, deci putem folosi condiția de ordin II pentru a arăta convexitatea. Mai exact, verificăm dacă  $\nabla^2 f(x) \geq 0$  pentru orice  $x \in \text{dom} f$ . Valorile proprii ale matricei  $Q$  sunt soluții ale polinomului caracteristic:

$$\lambda^2 - 12\lambda + 32 = 0,$$

date de  $\lambda_{1,2} = \{8, 4\}$ , i.e. matricea  $Q$  este pozitiv definită.

- (ii) Funcția  $f$  este convexă, deci condițiile de optimalitate de ordin I sunt suficiente pentru a determina punctul de optim:

$$\nabla f(x^*) = Qx^* + q = 0.$$

Evident, soluția  $x^* = -Q^{-1}q$  este determinată de  $Q^{-1} = \frac{1}{32} \begin{bmatrix} 6 & -2 \\ -2 & 6 \end{bmatrix}$  rezultând:

$$x^* = \frac{1}{32} \begin{bmatrix} 6 & -2 \\ -2 & 6 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{32} \begin{bmatrix} 4 \\ 4 \end{bmatrix} = \begin{bmatrix} \frac{1}{8} \\ \frac{1}{8} \end{bmatrix}$$

Implementarea primei iterații a metodei gradient presupune calculul vectorului  $\nabla f(x_0)$ :

$$\nabla f(x_0) = Qx_0 + q = \begin{bmatrix} 1 \\ 5 \end{bmatrix}.$$

Astfel, iterația  $x_1$  rezultă:

$$x_1 = x_0 - \alpha_0 \nabla f(x_0) = \begin{bmatrix} 0 \\ -4 \end{bmatrix}$$

Observăm că  $f(x_1) = 52$  și  $f(x^*) = -\frac{1}{8}$ , deci  $x_1$  se află într-o regiune relativ îndepărtată a optimului  $x^*$ . În plus, remarcăm că valoarea funcției în  $x_1$  este mai mare față de cea în  $x_0$ , i.e.  $f(x_0) = 2$ . Reamintim că aplicarea metodei gradient unei probleme cu funcția obiectiv cu gradient continuu în sens Lipschitz (cu constanta  $L$ ) presupune alegerea pasului  $\alpha \in (0, \frac{2}{L})$ . În particular,  $L = \lambda_{\max}(Q) = 8$  și conform teoriei  $\alpha_0 \in (0, 0.25]$ ; deci,  $\alpha_0 = 1$  ales anterior este inadecvat.

**Problema 5.** Fie funcția  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ,  $f(x) = 4x_1^2 + 3x_2^2 - 4x_1x_2 + x_1$ , punctul inițial  $x_0 = [-\frac{1}{8} \ 0]^T$  și direcția  $d_0 = [-\frac{1}{5} \ \frac{2}{5}]^T$ .

- (i) Este  $d_0$  o direcție de descreștere?
- (ii) Notând  $\phi(\alpha) = f(x_0 + \alpha d_0)$ , să se găsească valoarea  $\phi'(1)$ .
- (iii) Să se calculeze prima iterație  $x_1$  a metodei gradient (cu alegere ideală a dimensiunii pasului).

*Rezolvare.* (i) Pentru ca direcția  $d_k$  să fie direcție de descreștere, trebuie să satisfacă inegalitatea  $\nabla f(x_k)^T d_k < 0$ . Din expresia gradientului funcției  $f$ :

$$\nabla f(x) = \begin{bmatrix} 8x_1 - 4x_2 + 1 \\ 6x_2 - 4x_1 \end{bmatrix},$$

care în punctul  $x_0$  este  $\nabla f(x_0) = [0 \ 1/2]^T$ , observăm că  $\nabla f(x_0)^T d_0 = -1/5$ . Deci direcția  $d_0$  este direcție de descreștere.

(ii) Pentru calculul derivatei lui  $\phi(\alpha)$  rescriem  $f$  sub formă:

$$f(x) = \frac{1}{2}x^T Qx + q^T x, \quad \text{unde } Q = \begin{bmatrix} 8 & -4 \\ -4 & 6 \end{bmatrix} \text{ și } q = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Explicităm  $\phi(\alpha)$ :

$$\phi(\alpha) = \frac{\alpha^2}{2}d_0^T Qd_0 + \alpha(Qx_0 + q)^T d_0 + \frac{1}{2}x_0^T Qx_0 + q^T x_0,$$

și deducem derivata în 1:

$$\phi'(1) = d_0^T Qd_0 + (Qx_0 + q)^T d_0 = 0.44.$$

(iii) Substituind valorile parametrilor din enunț, problema găsirii dimensiunii ideale a pasului metodei gradient se reduce la minimizarea unei funcții scalare pătratice convexe. Rezultă astfel  $\min_{\alpha \geq 0} \phi(\alpha) = -0.0833$  și  $\alpha^* = \arg \min_{\alpha \geq 0} \phi(\alpha) = 0.1667$ . În final, calculăm prima iterație a metodei gradient:

$$x_1 = x_0 - \alpha^* \nabla f(x_0) = \begin{bmatrix} -0.1250 \\ -0.0833 \end{bmatrix}.$$

**Problema 6.** Fie problema de minimizare:

$$\min_{x \in \mathbb{R}^2} f(x) \quad (:= 5x_1^2 + 5x_2^2 - x_1x_2 - 11x_1 + 11x_2 + 11).$$

- (i) Să se găsească punctele critice.
- (ii) Să se demonstreze că un punct ce satisface condițiile de ordin I este, de asemenea, punct de minim global.
- (iii) Care este rata de descreștere a metodei gradient pentru această funcție ?
- (iv) Pornind din punctul inițial  $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ , câte iterații sunt necesare pentru ca algoritmul să atingă acuratețea  $10^{-6}$ ?

*Rezolvare.* (i) Punctele critice reprezintă soluțiile sistemului  $\nabla f(x) = 0$  descris de:

$$\begin{cases} 10x_1 - x_2 - 11 = 0 \\ -x_1 + 10x_2 + 11 = 0. \end{cases}$$



Observăm că sistemul are o singură soluție dată de perechea  $(x_1, x_2) = (1, -1)$ .

(ii) Observăm că funcția  $f$  în forma:

$$f(x_1, x_2) = \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 10 & -1 \\ -1 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + [-11 \quad 11] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 11.$$

are Hessiana pozitiv definită în orice punct al domeniului, i.e.

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} 10 & -1 \\ -1 & 10 \end{bmatrix} = Q \succ 0.$$

În concluzie, punctul critic  $(x_1^*, x_2^*) = (1, -1)$  este punct de minim global.

(iii) Pentru calculul ratei de descreștere corespunzătoare metodei gradient explicităm iterația acesteia:

$$\begin{aligned} x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\ &= x_k - \alpha_k (Qx_k + q) \\ &= x_k - \alpha_k Qx_k - \alpha_k q \\ &= (I_2 - \alpha_k Q)x_k - \alpha_k q, \end{aligned}$$

unde cu  $I_2$  am notat matricea identitate de ordin II. Considerăm metoda gradient cu pasul constant dat de  $\alpha_k = \frac{1}{L}$ , unde  $L$  reprezintă constanta de continuitate Lipschitz a gradientului funcției obiectiv.

Reamintim acum relația de continuitate în sens Lipschitz a gradientului unei funcții diferențiabile: o funcție  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  are gradientul continuu Lipschitz cu constanta  $L$  dacă

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \forall x, y \in \mathbb{R}^n.$$

În cazul funcției din enunț, relația se reduce la:

$$\|Qx - Qy\| \leq \|Q\|\|x - y\|, \forall x, y \in \mathbb{R}^2,$$

deci putem considera constanta Lipschitz  $L = \|Q\| = \lambda_{\max}(Q)$ , unde  $\lambda_{\max}(Q)$  reprezintă valoarea proprie maximă a lui  $Q$ . Observând că în cazul nostru  $\lambda_{\max}(Q) = L = 11$ , considerăm pasul constant  $\alpha_k = \frac{1}{11}$ .

Folosind notația  $x^* = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ , din condițiile de ordinul I avem  $Qx^* = -q$ ,

de aceea putem reformula iterația în următorul mod:

$$\begin{aligned}
 x_{k+1} - x^* &= x_k - \frac{1}{11}(Qx_k + q) - x^* \\
 &= x_k - \frac{1}{11}(Qx_k - Qx^*) - x^* \\
 &= \left(I_2 - \frac{1}{11}Q\right)(x_k - x^*) \\
 &\vdots \\
 &= \left(I_2 - \frac{1}{11}Q\right)^k (x_0 - x^*).
 \end{aligned}$$

De aici se poate deriva ușor rata de descreștere a metodei gradient:

$$\begin{aligned}
 \|x_{k+1} - x^*\| &= \left\| \left(I_2 - \frac{1}{11}Q\right)^k (x_0 - x^*) \right\| \\
 &\leq \left\| \left(I_2 - \frac{1}{11}Q\right)^k \right\| \|x_0 - x^*\| \\
 &= \|I_2 - \frac{1}{11}Q\|^k \|x_0 - x^*\|.
 \end{aligned}$$

În concluzie, metoda gradient are rata de descreștere liniară (pentru funcția din enunț) cu factorul  $\|I_2 - \frac{1}{11}Q\|$ .

(iv) Din punctul anterior, avem rata de convergență a șirului generat de metoda gradient cu pas constant:

$$\|x_k - x^*\| \leq \|I_2 - \frac{1}{11}Q\|^k \|x_0 - x^*\|. \quad (3.6)$$

Calculând norma Euclidiană (norma 2), avem:

$$\left\| I_2 - \frac{1}{11}Q \right\| = \left\| \begin{bmatrix} \frac{1}{11} & \frac{1}{11} \\ \frac{1}{11} & \frac{1}{11} \end{bmatrix} \right\| = \frac{2}{11}.$$

Înlocuind în (3.6) inclusiv valorile pentru  $x_0$  și  $x^*$ , avem:

$$\|x_k - x^*\| \leq \sqrt{2} \left( \frac{2}{11} \right)^k.$$

Pentru ca șirul  $x_k$  să se apropie de punctul de optim  $x^*$  cu acuratețea  $10^{-6}$ , trebuie să asigurăm inegalitatea  $\sqrt{2} \left( \frac{2}{11} \right)^k \leq 10^{-6}$ . În concluzie,

prin extragerea logaritmului din ambele părți, avem nevoie de un număr de iterații:

$$k \geq \frac{\sqrt{2} \log 10^6}{\log 11 - \log 2}.$$

**Problema 7.** Să se determine extremele funcției  $f(x_1, x_2) = x_1^3 x_2^2 (a - x_1 - x_2)$ . Pentru ce valori ale lui  $a$ , funcția  $f$  are un punct de maxim global?

*Rezolvare.* Obținem punctele de extrem ale funcției rezolvând sistemul dat de condițiile de ordin I, i.e.  $\nabla f(x_1, x_2) = 0$ . Mai exact, sistemul are forma:

$$\begin{cases} 3x_1^2 x_2^2 (a - x_1 - x_2) - x_1^3 x_2^2 = 0 \\ 2x_1^3 x_2 (a - x_1 - x_2) - x_1^3 x_2^2 = 0 \end{cases} \Rightarrow \begin{cases} x_1^2 x_2^2 (3a - 4x_1 - 3x_2) = 0 \\ x_1^3 x_2 (2a - 2x_1 - 3x_2) = 0, \end{cases}$$

de unde putem deduce trei cazuri diferite:

$$\begin{cases} x_1 = 0 \\ x_2 \text{ oarecare} \end{cases} \quad \text{sau} \quad \begin{cases} x_1 \text{ oarecare} \\ x_2 = 0 \end{cases} \quad \text{sau} \quad \begin{cases} 3a - 4x_1 - 3x_2 = 0 \\ 2a - 2x_1 - 3x_2 = 0 \end{cases}.$$

Componentele Hessienei  $\nabla^2 f(x_1, x_2)$  vor fi:

$$\begin{aligned} \frac{\partial^2 f}{\partial x_1^2} &= 2x_1 x_2^2 (3a - 6x_1 - 3x_2), & \frac{\partial^2 f}{\partial x_2^2} &= x_1^3 (2a - 2x_1 - 5x_2) \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} &= \frac{\partial^2 f}{\partial x_2 \partial x_1} = x_1^2 x_2 (6a - 8x_1 - 9x_2), \end{aligned}$$

Constatăm că în primele două cazuri,  $x_1 = 0$  sau  $x_2 = 0$ , matricea

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

este nedefinită. Pentru ultimul caz însă, obținem  $x_1 = \frac{a}{2}$  și  $x_2 = \frac{a}{3}$ . Astfel, observăm că:

$$\nabla^2 f\left(\frac{a}{2}, \frac{a}{3}\right) = \begin{bmatrix} \frac{-a^4}{9} & \frac{-a^3}{4} \\ \frac{-a^3}{4} & \frac{-a^4}{12} \end{bmatrix}$$

iar parametrul  $a$  condiționează natura punctului critic  $(\frac{a}{2}, \frac{a}{3})$ . În final, pentru ca acesta să fie un punct de maxim este necesar ca  $\nabla^2 f\left(\frac{a}{2}, \frac{a}{3}\right) \preceq 0$ , i.e.  $a \in [-\frac{3}{2}, 0)$ .

**Problema 8.** Fie funcția  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  convexă și diferențiabilă. Să se deducă iterația metodei gradient cu pas constant  $\alpha = \frac{1}{5}$  prin intermediul aproximării Taylor pătratice cu Hessiana  $5I_n$ .

*Rezolvare.* În orice punct al domeniului acesteia, funcția  $f$  se poate aproxima cu o formă pătratică după cum urmează:

$$f(x) \approx f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + \frac{\beta}{2}\|x - \bar{x}\|^2,$$

oricare ar fi  $\bar{x} \in \text{dom} f$  și  $\beta \geq 0$ . Precizăm că partea dreaptă a expresiei anterioare se numește *aproximarea pătratică a funcției  $f$  în punctul  $\bar{x}$  cu Hessiana  $\beta I_n$* .

Iterația metodei gradient cu pas constant  $\alpha$  se deduce din minimizarea, la fiecare pas  $k$ , a aproximării pătratice cu Hessiana  $\frac{1}{\alpha}I_n$ :

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T(y - x_k) + \frac{1}{2\alpha}\|y - x_k\|^2.$$

Observând că se presupune minimizarea unei funcții convexe, determinăm minimul explicit prin intermediul condițiilor de optimalitate de ordin I:

$$\nabla f(x_k) + \frac{1}{\alpha}(y^* - x_k) = 0,$$

de unde în final deducem:

$$x_{k+1} = y^* = x_k - \alpha \nabla f(x_k).$$

### 3.4 Probleme propuse

**Problema 1.** Fie funcția  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $f(x) = \frac{1}{2}[x^T x + \frac{1}{2}(a^T x)^2]$ . Să se deducă numărul de flopi necesari pentru calcularea următoarelor elemente:  $f(x)$ ,  $\nabla f(x)$ ,  $\nabla^2 f(x)$  și  $\nabla^2 f(x)d$ , unde  $d \in \mathbb{R}^n$  este un vector oarecare.

**Problema 2.** Pentru următoarele funcții determinați toate punctele staționare și verificați dacă acestea sunt puncte de minim local prin utilizarea condițiilor suficiente de optimalitate de ordinul II:

(i)  $f(x) = 3x_1 + \frac{100}{x_1 x_2} + 5x_2,$

$$(ii) \quad f = (x_1 - 1)^2 + x_1 x_2 + (x_2 - 1)^2,$$

$$(iii) \quad f = \frac{x_1 + x_2}{3 + x_1^2 + x_2^2 + x_1 x_2}.$$

**Problema 3.** Fiind dată funcția  $f(x_1, x_2) = x_1^2 + 25x_2^2$  și un punct  $x_0 = [5 \quad 1]^T$ , se cere:

- (i) Să se construiască explicit  $\phi(\alpha)$  de-a lungul celei mai abrupte pante, i.e.  $\phi(\alpha) = f(x_0 - \alpha \nabla f(x_0))$ .
- (ii) Să se minimizeze  $\phi(\alpha)$  în funcție de  $\alpha$  și să se obțină un nou punct  $x_1$  utilizând iterația metodei gradient.

**Problema 4.** Să se aplice metoda gradientilor conjugați pentru minimizarea neconstrânsă funcției definite în problema rezolvată 5. Să se verifice în două moduri validitatea punctului de optim obținut.

**Problema 5.** Fie o matrice  $Q \succ 0$ . Să se demonstreze inegalitatea lui Kantorovich definită de următoarea relație:

$$\frac{(x^T x)^2}{(x^T Q x)(x^T Q^{-1} x)} \geq \frac{4\lambda_{\max}(Q)\lambda_{\min}(Q)}{[\lambda_{\max}(Q) + \lambda_{\min}(Q)]^2}.$$

**Problema 6.** Să se discute valorile parametrului  $n$  astfel încât funcția  $f(x_1, x_2) = x_1^n + x_2^n - x_1 x_2 n$  să aibă puncte de extrem local.

**Problema 7.** Fie funcția  $f(x) = x_1^4 + x_1 x_2 + (1 + x_2)^2$ . Definim modelul pătratic:

$$q_f(x; x_0) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{1}{2\alpha} \|x - x_0\|^2.$$

Se observă că iterația metodei gradient cu dimensiunea pasului  $\alpha$  este punctul de minim al formei pătratice anterioare, i.e.

$$\begin{aligned} x_1 &= x_0 - \alpha \nabla f(x_0) \\ &= \arg \min_{y \in \mathbb{R}^2} f(x_0) + \langle \nabla f(x_0), y - x_0 \rangle + \frac{1}{2\alpha} \|y - x_0\|^2. \end{aligned}$$

- (i) Pentru  $x_0 = [0 \quad 0]^T$ , să se calculeze  $\nabla f(x_0)$  și  $\nabla^2 f(x_0)$  și să se demonstreze că  $\nabla^2 f(x_0)$  nu este pozitiv definită.
- (ii) Pentru  $x_0 = [1 \quad -1]^T$ , să se calculeze prima iterație a metodei de gradient cu pasul  $\alpha = 1$ .

**Problema 8.** Fie funcția  $f(x) = x_1^2 + 2x_2^2 + 4x_1 + 4x_2$ . Să se demonstreze prin inducție că metoda gradient cu pasul ideal, pornind din  $x_0 = [0 \ 0]^T$ , generează șirul dat de:

$$x_{k+1} = \begin{bmatrix} \frac{2}{3^k} - 2 \\ \left(-\frac{1}{3}\right)^k - 1 \end{bmatrix}.$$

Să se deducă punctul de minim din șirul rezultat.

**Problema 9.** Să se găsească punctele critice ale funcției:

$$f(x) = 2x_1^3 - 3x_1^2 - 6x_1x_2(x_1 - x_2 - 1).$$

Care din aceste puncte sunt minime locale, maxime locale sau niciuna din variante?

**Problema 10.** Pentru problema de optimizare:

$$\min_{x \in \mathbb{R}^2} 4x_1^2 - 4x_1x_2 + 2x_2^2,$$

să se aplice primele trei iterații ale metodei gradient cu pasul ales în mod ideal.

**Problema 11.** Considerăm următoarea iterație tip metodă gradient:

$$x_{k+1} = x_k - s(\nabla f(x_k) + e_k),$$

unde  $s$  este un pas constant,  $e_k$  este o eroare ce satisface  $\|e_k\| \leq \delta$  pentru orice  $k$ , iar  $f$  este funcția pătratică pozitiv definită:

$$f(x) = \frac{1}{2}(x - x^*)^T Q(x - x^*)$$

Fie  $q = \max\{|1 - sm|, |1 - sM|\}$ , unde  $m$  și  $M$  sunt cea mai mică, respectiv cea mai mare valoare proprie a lui  $Q$ . Presupunem că  $q < 1$ . Să se demonstreze că pentru orice  $k$  avem:

$$\|x_k - x^*\| \leq \frac{s\delta}{1 - q} + q^k \|x_0 - x^*\|$$

# Capitolul 4

## Metode de ordinul II

### 4.1 Preliminarii

În acest capitol considerăm, de asemenea, probleme generale de optimizare neconstrânsă de forma (3.1). Dacă metodele de ordinul I expuse în capitolul anterior se bazează pe informația de gradient a funcției obiectiv, în următoarele secțiuni analizăm algoritmi ce fac uz în plus și de informația de ordinul II, și anume matricea Hessiană a funcției obiectiv (vezi [1, 3]). În cele ce urmează prezentăm pe scurt condițiile de optimalitate necesare și suficiente pentru probleme de optimizare fără constrângeri (restricții) (3.1).

*Condițiile necesare de optimalitate* pentru problemele neconstrânse pot fi enunțate astfel: orice punct de minim local  $x^* \in \text{dom} f$  al problemei (3.1) satisface  $\nabla f(x^*) = 0$ . De asemenea, *condițiile necesare de ordinul II* se pot formula după cum urmează: orice punct de minim local  $x^* \in \text{dom} f$  al problemei (UNLP) satisface:

$$\nabla f(x^*) = 0 \quad \text{și} \quad \nabla^2 f(x^*) \succeq 0.$$

Atribuim o importanță majoră *condițiilor de optimalitate suficiente* de ordinul II deoarece reprezintă o modalitate de verificare a naturii unui punct dat: dacă  $x^*$  satisface

$$\nabla f(x^*) = 0 \quad \text{și} \quad \nabla^2 f(x^*) \succ 0,$$

atunci  $x^*$  este un punct strict de minim local al problemei (3.1). Intuitiv, dacă algoritmi de ordinul I rezolvă condițiile necesare de ordinul I cu ajutorul informației de gradient, putem argumenta că cei de ordinul II

converg la un punct de minim local ce satisface condițiile de ordinul I și II, utilizând în plus matricea Hessiană a funcției obiectiv. În continuare, prezentăm principalele metode de ordinul II și analizăm comportamentul acestora pe exemple numerice.

*Metoda Newton* reprezintă una dintre cele mai vechi metode de optimizare, dezvoltată inițial în scopul aproximării iterative a soluțiilor ecuațiilor neliniare. Această metodă utilizează inversa matricei Hessiene a funcției obiectiv pentru o convergență rapidă către un punct de minim local. Principalul dezavantaj al metodei Newton îl reprezintă instabilitatea provocată de anumiți factori (e.g. inițializarea într-o regiune îndepărtată de optim, condiționarea matricei Hessiene). Cu toate acestea, în cazurile bine condiționate când metoda converge, prezintă o convergență mult superioară metodelor de ordinul I. Ideea principală ce stă la baza metodei Newton o reprezintă aproximarea funcției obiectiv: pentru funcția obiectiv  $f$  a problemei (3.1), la iterația  $k$  se construiește aproximarea pătratică  $\hat{f} \approx f$  (aproximarea Taylor de ordinul II) a funcției obiectiv în punctul curent  $x_k$ :

$$\hat{f}(x) = f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k),$$

care se minimizează cu scopul obținerii iterației Newton. Dacă  $\nabla^2 f(x_k)$  este pozitiv definită, atunci funcția  $\hat{f}(x)$  este convexă. Pe de altă parte, gradientul funcției  $\hat{f}(x)$  este dat de:

$$\nabla \hat{f}(x) = \nabla^2 f(x_k) (x - x_k) + \nabla f(x_k),$$

iar minimul funcției  $\hat{f}(x)$  va fi atins într-un punct  $\bar{x}$  ce satisface  $\nabla \hat{f}(\bar{x}) = 0$ . Considerând următorul punct  $x_{k+1}$  al șirului ca fiind punctul ce anulează gradientul funcției  $\hat{f}(x)$ , i.e.  $\nabla \hat{f}(x_{k+1}) = 0$ , implicit vom obține sistemul liniar de ecuații:

$$\nabla^2 f(x_k) (x_{k+1} - x_k) = -\nabla f(x_k), \quad (4.1)$$

de unde rezultă iterația metodei Newton standard:

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k).$$

Varianta generală a metodei Newton este dată de iterația:

$$x_{k+1} = x_k - \alpha_k (\nabla^2 f(x_k))^{-1} \nabla f(x_k),$$



considerând selectarea pasului  $\alpha_k$  prin aceleași moduri ca la metodele de ordinul I: line search (ideal), backtracking sau  $\alpha_k = \alpha$  constant. Observăm că metoda Newton standard are dimensiunea pasului unitar constant, i.e.  $\alpha_k = 1$ .

Dacă funcția  $f$  este pătratică strict convexă (i.e.  $\nabla^2 f(x) \succ 0$  pentru orice  $x$ ), atunci metoda Newton converge într-un singur pas către punctul de minim. În general, metoda Newton nu converge decât dacă inițializarea se realizează în vecinătatea punctului de minim. Există două motivații pentru acest comportament: (i) dacă funcția obiectiv  $f$  este puternic neliniară atunci  $\hat{f}$  este o aproximare inexactă lui  $f$ , de aceea există posibilitatea ca  $f(x_{k+1}) > f(x_k)$ ; (ii) nu avem garanția că  $\nabla^2 f(x_k) \succ 0$  pe parcursul iterațiilor metodei. Mai exact, dacă  $\nabla^2 f(x_k) \not\succ 0$  sau  $\det(\nabla^2 f(x_k)) = 0$ , atunci este posibil ca  $\hat{f}(x)$  să nu aibă punct de minim. Implementarea metodei Newton necesită abordarea a doi factori importanți:

(i) este necesară implementarea unei reguli de alegere a dimensiunii pasului  $\alpha_k$ , astfel încât să eliminăm posibilitatea de creștere a funcției obiectiv în punctele depărtate de optim, fapt datorat impreciziei aproximării pătratice. În cazul în care funcția obiectiv nu este convexă, însă problema de minimizare admite o soluție, atunci inversa Hessienei nu este pozitiv definită în mod cert decât în apropierea soluției;


(ii) dacă nu putem asigura ca Hessiana este pozitiv definită în fiecare punct al șirului  $\{x_k\}_{k \geq 0}$ , o abordare des întâlnită presupune înlocuirea Hessienei cu o matrice Hessiană modificată  $G = \epsilon I_n + \nabla^2 f(x) \succ 0$ , cu  $\epsilon \geq 0$ . Menționăm că întotdeauna va exista un  $\epsilon$  suficient de mare astfel încât  $G \succ 0$ . Reamintim că cel mai simplu algoritm pentru a verifica dacă o matrice dată este sau nu pozitiv definită este factorizarea Cholesky.

## 4.2 Probleme rezolvate de laborator

### 4.2.1 Metoda Newton

**Exemplul 18.** Să se implementeze metoda Newton cu cele trei variante de alegere a dimensiunii pasului (ideal, backtracking, pas unitar constant) pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^2} f(x) \quad (= (x_1 - x_2^3)^2 + 3(x_1 - x_2)^4). \quad (4.2)$$



**Figura 4.1:** Comparația convergenței metodei Newton utilizând cele trei opțiuni pentru selectarea pașilor: ideal (linie continuă), backtracking (linie punctată întreruptă) și pas constant unitar (linie întreruptă) pentru problema (4.2).

*Rezolvare.* Utilizăm funcții auxiliare ce returnează informații de ordinul I și II:

```
[f,g]=f_obj(x)
H=hess_obj(x).
```

Funcția `f_obj` returnează valoarea  $f(x)$  și  $\nabla f(x)$  prin variabilele `f,g`, `hess_obj` returnează  $\nabla^2 f(x)$  prin variabile `H`. Pentru selectarea pasului ideal, construim funcția:

```
f=alpha_search(alpha,x,d)
```

ce returnează  $f(x + \alpha d)$  în  $f$ . De asemenea, pentru metoda backtracking construim funcția:

```
alpha=alpha_bactrack(x,d).
```

Condiția de oprire va fi aceeași ca și în cazul metodei gradient, anume  $\|\nabla f(x_k)\| < \epsilon$ , unde  $\epsilon > 0$  reprezintă acuratețea dorită. Secvența de cod ce implementează metoda Newton este prezentată în cele ce urmează:

```
function xmin=newton_method(x0,eps)
%initializam vectori/matrice pentru memorarea gradientilor,
%a punctelor x generate de algoritm, etc
puncte_gradient=[];
puncte_iteratie=[];
```

---


```

valori_functie=[];
norme_gradienti=[];
%vom utiliza un vector g pentru a stoca gradientul curent
%o matrice H pentru a stoca Hessiana curenta
%calculam directia corespunzatoare in d
x=x0;
[f,g]=f_obj(x);
while(norm(g)>eps)
    [f,g]=f_obj(x);
    H=hess_obj(x);
    d=H\ -g;
    puncte_gradient=[puncte_gradient g];
    puncte_iteratie=[puncte_iteratie x];
    valori_functie=[valori_functie; f];
    norme_gradienti=[norme_gradienti; norm(g)];
    %Aici selectam alpha=1 constant,
    %alpha=fminbnd(...) pentru exact line search,
    %sau alpha=alpha_bactrack(...)
    %pentru metoda de backtracking
    alpha=fminbnd(@(alpha) alpha_search(alpha,x,d),0,1);
    x=x+alpha*d
end
xmin=x;

%Pentru afisarea grafica a rezultatelor,
%avem urmatoarele instructiuni
t=1:length(valori_functie);
figure(1)
hold on
plot(t,norme_gradienti(t),'k','LineWidth',2);
hold off
figure(2)
hold on
plot(t,valori_functie(t),'k','LineWidth',2);
hold off

%Pentru trasarea liniilor de contur si evolutia
%metodei gradient, avem urmatoarele instructiuni
[x1,x2]=meshgrid([1.2:0.01:2.8],[0.4:0.01:1.6]);

```



**Figura 4.2:** *Graficul punctelor obținute de metoda Newton cu pas ideal și liniile de contur aferente pentru problema (4.2).*

```

z=(x1-2).^4+(x1-2.*x2).^2;
figure(3)
hold on
contour(x1,x2,z,valor_i_functie)
plot3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valor_i_functie,'r')
scatter3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valor_i_functie,'filled')
hold off

```

Rezultatele comparative pentru metoda Newton utilizând cele trei opțiuni pentru selectarea pasului pot fi observate în Fig. 4.1. În Fig. 4.2 observăm punctele obținute de metoda Newton și curbele de nivel aferente.

### 4.2.2 Metode cvasi-Newton

Deși metoda Newton prezintă convergență pătratică, în multe cazuri ea prezintă dezavantaje din punct de vedere al efortului de calcul datorită necesității calculului derivatelor de ordinul I și a rezolvării sistemului de ecuații (4.1) la fiecare iterație. Pentru probleme de dimensiuni mari ce nu pot fi abordate cu metoda Newton au fost dezvoltate metode de tip *cvasi-Newton*. Această clasă de metode presupun înlocuirea matricei Hessiene cu una simetrică pentru care operația de inversare nu este costisitoare. Șirul de matrice rezultat permite evitarea calculului derivatelor de ordinul II și simplifică rezolvarea sistemului de ecuații (4.1) necesar determinării direcției. Un algoritm de tip cvasi-Newton este definit de următoarea schemă:

Fie punctul inițial  $x_0 \in \text{dom} f$  și matricea inițială  $H_0 \succ 0$ . Pentru  $k \geq 1$ , cât timp criteriul de oprire nu este satisfăcut, iterăm:

1. se calculează direcția cvasi-Newton  $d_k = -H_k^{-1} \nabla f(x_k)$ ;
2. se determină pasul  $\alpha_k$  (e.g. prin metoda de backtracking);
3. se calculează următoarea iterație:  $x_{k+1} = x_k + \alpha_k d_k$ ;
4. se calculează o nouă matrice  $H_{k+1}$ .

Metodele de tip cvasi-Newton diferă prin regula de actualizare a matricei  $H_k$ . Cea mai des utilizată variantă este metoda *Broyden-Fletcher-Goldfarb-Shanno* (sau metoda BFGS pe scurt):

$$H_k = H_{k-1} + \frac{\delta_k \delta_k^T}{\delta_k^T \Delta_k} - \frac{H_{k-1} \Delta_k \Delta_k^T H_{k-1}}{\Delta_k^T H_{k-1} \Delta_k},$$

unde

$$\Delta_k = x_k - x_{k-1}, \delta_k = \nabla f(x_k) - \nabla f(x_{k-1}).$$

O altă versiune a metodei BFGS consideră actualizarea directă a inversei matricei  $H_k$ :

$$H_k^{-1} = \left( I - \frac{\Delta_k \delta_k^T}{\delta_k^T \Delta_k} \right) H_{k-1}^{-1} \left( I - \frac{\delta_k \Delta_k^T}{\delta_k^T \Delta_k} \right) + \frac{\Delta_k \Delta_k^T}{\delta_k^T \Delta_k}.$$

Structura algoritmului cvasi-Newton cu actualizare BFGS este definită de următoarea schemă:

Selectăm un punct inițial  $x_0 \in \mathbb{R}^n$ , o toleranță  $\epsilon > 0$  și o matrice  $H_0 \in \mathbb{R}^{n \times n}$  simetrică și pozitiv definită. Cât timp  $\|\nabla f(x_k)\| > \epsilon$ ,

1. calculăm direcția  $d_k = -H_k^{-1} \nabla f(x_k)$ ;
2. calculăm pasul  $\alpha_k = \arg \min_{\alpha > 0} f(x_k + \alpha d_k)$ ;
3. calculăm noua iterație  $x_{k+1} = x_k + \alpha_k d_k$  și  $\Delta_k = \alpha_k d_k$ ;
4. evaluăm  $\nabla f(x_{k+1})$  și calculăm  $\delta_k = \nabla f(x_{k+1}) - \nabla f(x_k)$ ;
5. calculăm  $H_{k+1}$  prin formula BFGS;  $k = k + 1$ .

O observație importantă este diferența dintre rata de convergență locală a metodei Newton și a metodelor de tip cvasi-Newton. Cu toate că metodele cvasi-Newton prezintă o complexitate per iterație mai mică, rata de convergență este (super)liniară în timp ce metoda Newton prezintă o rată de convergență pătratică locală.

## 4.3 Probleme rezolvate de seminar

### 4.3.1 Metoda Newton și metoda BFGS

**Problema 1.** Fie problema de optimizare

$$\min_{x \in \mathbb{R}^n} f(x)$$

unde  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  este pătratică, i.e.  $f(x) = \frac{1}{2}x^T Qx + q^T x$ . Să se arate că pentru  $f$  convexă metoda Newton standard converge într-un singur pas.

*Rezolvare.* Din condițiile de optimalitate de ordinul I, i.e.  $\nabla f(x) = Qx + q = 0$  va rezulta că  $x^* = -Q^{-1}q$ . Reținem că direcția metodei Newton este  $d = -(\nabla f(x))^{-1} \nabla f(x)$ , care în cazul pătratic va fi:

$$d = -Q^{-1}(Qx + q) = -x - Q^{-1}q.$$

Astfel, pentru un punct inițial  $x_0$  și un pas  $\alpha_0 = 1$ , vom avea:

$$x_1 = x_0 + \alpha_0 d_0 = x_0 - x_0 - Q^{-1}q = -Q^{-1}q.$$

Din moment ce  $f$  este convexă, va rezulta automat că  $\nabla^2 f(x_0) = Q \succeq 0$ , iar drept urmare  $x_1 = x^*$ .

**Problema 2.** Fie funcția  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  convexă și diferențiabilă de două ori. Să se determine expresia iterației metodei Newton standard prin intermediul aproximării Taylor de ordinul II. Este posibilă și o altă modalitate de a obține această iterație?

*Rezolvare.* Deoarece funcția  $f$  este diferențiabilă de două ori, în orice punct al domeniului acesteia  $\bar{x} \in \text{dom} f$ , se poate aproxima cu o formă pătratică:

$$f(x) \approx f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}).$$

Precizăm că partea dreaptă a expresiei anterioare se numește *aproximarea Taylor de ordinul II în punctul  $\bar{x}$  a funcției  $f$* .

Fie punctul curent  $x_k$  al metodei Newton, următoarea iterație  $x_{k+1}$  se determină din minimizarea neconstrânsă a aproximării de ordinul II în punctul  $x_k$  a funcției obiectiv:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T (y - x_k) + \frac{1}{2}(y - x_k)^T \nabla^2 f(x_k)(y - x_k).$$

Deoarece funcția  $f$  este convexă, matricea  $\nabla^2 f(x_k)$  este pozitiv semi-definită, deci aproximarea pătratică este convexă. Determinăm punctul de minim al acestei aproximări din condițiile de optimalitate de ordinul I:

$$\nabla^2 f(x_k)(y^* - x_k) + \nabla f(x_k) = 0,$$

de unde rezultă iterația:

$$x_{k+1} = y^* = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

O modalitate alternativă de a deduce iterația Newton este descrisă de liniarizarea expresiei gradientului funcției obiectiv în punctul curent  $x_k$ :

$$\nabla f(x) \approx \nabla f(\bar{x}) + \nabla^2 f(\bar{x})(y - \bar{x}),$$

unde considerăm  $\nabla f(\bar{x})$  și  $\nabla^2 f(\bar{x})$  cunoscute. Pentru a obține iterația Newton, la momentul  $k + 1$ , egalăm cu 0 aproximarea liniară a gradientului, în punctul  $x_k$ :

$$\nabla f(x_k) + \nabla^2 f(x_k)(y^* - x_k) = 0,$$

de unde rezultă:

$$x_{k+1} = y^* = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

Menționăm în plus că iterația metodei Newton generale

$$x_{k+1} = x_k - \alpha_k [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

se obține din minimizarea unei aproximări Taylor pătratice de forma:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T (y - x_k) + \frac{1}{2\alpha_k} (y - x_k)^T \nabla^2 f(x_k) (y - x_k).$$

De asemenea, iterația metodei gradient  $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$  se poate obține dintr-o aproximare pătratică de forma:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T (y - x_k) + \frac{1}{2\alpha_k} \|y - x_k\|^2.$$

**Problema 3.** Fie problema de optimizare neconstrânsă:

$$\min_{x \in \mathbb{R}^2} f(x) \quad \left( = \frac{1}{2}x_1^2 + \frac{5}{2}x_2^2 + 2x_1x_2 + 2x_1 + 4x_2 \right).$$

- (i) Să se scrie problema ca o problemă QP (*Quadratic Programming*). Să se arate că problema este convexă.
- (ii) Să se determine punctul de minim  $x^*$  al problemei.
- (iii) Pornind din punctul  $x^0 = [1 \ -1]^T$ , să se determine pasul optim  $\alpha_0$  corespunzător metodei gradient și să se implementeze prima iterație a acestei metode cu pasul obținut.
- (iv) Să se implementeze prima iterație a metodei Newton standard pentru problema precedentă. Să se compare punctul  $x_1$  al metodei gradient cu cel al metodei Newton. Ce se observă?

*Rezolvare.* (i) Prin rescrierea sub formă matriceală a funcției obiectiv ajungem la forma QP:

$$f(x) = \frac{1}{2}x^T \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix} x + [2 \ 4] x.$$

Pentru a determina convexitatea funcției, verificăm dacă matricea Hessiană:

$$\nabla^2 f(x) = Q = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}$$

este pozitiv semidefinită. Observăm că minorii principali sunt strict pozitivi, rezultând că Hessiana este pozitiv definită.

- (ii) Deoarece funcția obiectiv este strict convexă, punctul de minim neconstrâns este dat de condițiile de optimalitate de ordinul I:

$$\nabla f(x^*) = Qx^* + q = 0,$$

unde  $q = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$  și de unde rezultă soluția unică  $x^* = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$ .

- (iii) Reamintim procedura de selectare a lungimii ideale a pasului:

$$\alpha_0 = \arg \min_{\alpha \geq 0} \phi(\alpha) = \arg \min_{\alpha \geq 0} f(x_0 - \alpha \nabla f(x_0)). \quad (4.3)$$



Obținând direcția de gradient  $d_0 = -\nabla f(x_0) = Qx_0 + q = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$ , evaluăm funcția obiectiv:

$$\begin{aligned}\phi(\alpha) &= f(x_0 - \alpha \nabla f(x_0)) = \frac{1}{2} [(1 - \alpha)^2 + 5(1 + \alpha)^2] - 2(1 - \alpha^2) - 6\alpha - 2 \\ &= 5\alpha^2 - 2\alpha - 1.\end{aligned}$$

Observăm că punctul de minim global neconstrâns al funcției  $\phi(\alpha)$  este  $\alpha^* = \frac{1}{5}$ . Deoarece problema (4.3) este constrânsă, iar punctul de minim neconstrâns  $\alpha^*$  se află în mulțimea fezabilă  $\{\alpha \in \mathbb{R} : \alpha \geq 0\}$ , concluzionăm că lungimea ideală a pasului este  $\alpha_0 = \frac{1}{5}$ . Prima iterație a metodei gradient cu pas ideal este dată de:

$$x_1^G = x_0 - \alpha_0 \nabla f(x_0) = \begin{bmatrix} \frac{4}{5} \\ -\frac{6}{5} \end{bmatrix}.$$

(iv) Metoda Newton standard presupune următoarea iterație:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

În cazul nostru, funcția obiectiv este pătratică (implicit de două ori diferențiabilă) cu Hessiana:

$$\nabla^2 f(x) = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}.$$

Calculăm inversa matricei Hessiene:

$$[\nabla^2 f(x)]^{-1} = \begin{bmatrix} 5 & -2 \\ -2 & 1 \end{bmatrix},$$

iar primul pas al metodei Newton standard este dat de:

$$x_1^N = x_0 - [\nabla^2 f(x_0)]^{-1} \nabla f(x_0) = \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \begin{bmatrix} 5 & -2 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \end{bmatrix} = x^*.$$

În concluzie, metoda Newton converge pentru această problemă într-un singur pas către punctul de minim.

**Problema 4.** Fie funcția  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ , definită de:

$$f(x_1, x_2) = \frac{x_1^4}{4} + \frac{x_2^4}{4} - \frac{x_1^3}{3} - \frac{x_2^3}{3}.$$

(i) Să se determine un punct de minim local al problemei:

$$\min_{x \in \mathbb{R}^2} f(x)$$

(ii) Să se calculeze prima iterație a metodei Newton alegând punctul inițial  $x^0 = [-1 \ 1]^T$  și considerând cazurile în care pasul  $\alpha_0 = 1$  și  $\alpha_0$  este selectat ideal.

*Rezolvare.* (i) Calculăm mai întâi expresia gradientului și Hessienei:

$$\nabla f(x) = \begin{bmatrix} x_1^3 - x_1^2 \\ x_2^3 - x_2^2 \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} 3x_1^2 - 2x_1 & 0 \\ 0 & 3x_2^2 - 2x_2 \end{bmatrix}.$$

Din condiția  $\nabla f(x^*) = 0$  deducem că componentele lui  $x^*$  satisfac condiția  $x_1^*, x_2^* \in \{0, 1\}$ , iar pentru  $x^* = [1 \ 1]^T$  avem:

$$\nabla^2 f(1, 1) = I_2 \succ 0,$$

deci  $x^* = [1 \ 1]^T$  este punct de minim strict local.

(ii) Pentru punctul inițial  $x^0 = [-1 \ 1]^T$  avem:

$$\nabla f(x^0) = \begin{bmatrix} -2 \\ 0 \end{bmatrix}, \quad \nabla^2 f(x^0) = \begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix} \quad [\nabla^2 f(x^0)]^{-1} = \begin{bmatrix} \frac{1}{5} & 0 \\ 0 & 1 \end{bmatrix},$$

de unde rezultă direcția Newton:

$$d_0 = -[\nabla^2 f(x^0)]^{-1} \nabla f(x^0) = \begin{bmatrix} d_1^0 \\ d_2^0 \end{bmatrix} = \begin{bmatrix} \frac{2}{5} \\ 0 \end{bmatrix}.$$

Acum, pentru determinarea pasului ideal, trebuie să calculăm  $\phi(\alpha) = f(x_0 + \alpha d_0)$  pentru funcția noastră obiectiv:

$$\begin{aligned} \phi(\alpha) &= \frac{1}{4}(x_1 + \alpha d_1^0)^4 + \frac{1}{4}(x_2 + \alpha d_2^0)^4 - \frac{1}{3}(x_1 + \alpha d_1^0)^3 - \frac{1}{3}(x_2 + \alpha d_2^0)^3. \\ &= \frac{1}{4}\left(x_1 + \frac{2\alpha}{5}\right)^4 - \frac{1}{3}\left(x_1 + \frac{2\alpha}{5}\right)^3 + \frac{x_2^4}{4} - \frac{x_2^3}{3}. \end{aligned}$$

Rezolvăm ecuația  $\phi'(\alpha) = 0$ , de unde obținem  $\alpha^* = 5$ . Astfel, pentru pasul  $\alpha_0 = 1$ , respectiv  $\alpha_0 = 5$  iterațiile sunt date de:

$$x_1 = \begin{bmatrix} \frac{3}{5} \\ 1 \end{bmatrix}, \quad x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} = x^*.$$

Evaluând funcția obiectiv în cele două puncte  $f(3/5, 1) = 0.0211$ ,  $f(1, 1) = -0.1667$ , constatăm o descreștere mai bună cu dimensiunea ideală a pasului.

**Problema 5.** Dacă efectuăm o actualizare de rang 1 asupra unei matrice pătrate și nesarabile  $A$  și notăm rezultatul cu  $\bar{A}$ , i.e.:

$$\bar{A} = A + uv^T,$$

unde  $a, b \in \mathbb{R}^n$ , atunci formula Sherman-Morrison-Woodbury are loc:

$$\bar{A}^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}. \quad (4.4)$$

*Rezolvare.* Pentru a verifica această formulă, conform definiției matricei inverse, avem egalitatea  $\bar{A}^{-1}\bar{A} = I_n$ . Astfel, simplu înmulțim pe  $\bar{A}$  cu  $\bar{A}^{-1}$ :

$$\begin{aligned} \bar{A}^{-1}\bar{A} &= \left( A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} \right) (A + uv^T) \\ &= I_n + A^{-1}uv^T - \frac{A^{-1}uv^T + A^{-1}u(v^T A^{-1}u)v^T}{1 + v^T A^{-1}u} \\ &= I_n + A^{-1}uv^T - \frac{A^{-1}uv^T + (v^T A^{-1}u)A^{-1}uv^T}{1 + v^T A^{-1}u} \\ &= I_n + A^{-1}uv^T - \frac{1 + v^T A^{-1}u}{1 + v^T A^{-1}u} A^{-1}uv^T = I_n. \end{aligned}$$

**Problema 6.** Fie funcția  $f: \mathbb{R} \rightarrow \mathbb{R}$ , definită de  $f(x) = (x-1)^2/(x^2+1)$ . Să se implementeze metoda Newton pornind din punctele inițiale  $x_0 = \{-2, 0, -1\}$ . Ce se observă?

*Rezolvare.* Calculăm mai întâi gradientul funcției și Hessiana:

$$\nabla f(x) = \frac{2(x^2 - 1)}{(x^2 + 1)^2}, \quad \nabla^2 f(x) = \frac{4x(3 - x^2)}{(x^2 + 1)^3}.$$

Din condițiile de optimalitate va rezulta desigur că  $x^* = 1$  este punct de minim local strict. Utilizând expresiile obținute ale gradientului și Hessiane, deducem expresia direcției Newton:

$$d(x) = -[\nabla^2(f(x))]^{-1}\nabla f(x) = -\frac{x^4 - 1}{2x(3 - x^2)}.$$

Astfel, pentru punctele inițiale avem:

$$d(-2) = \frac{-15}{4}, \quad d(-1) = 0,$$

iar în  $x_0 = 0$  avem  $\nabla^2 f(0) = 0$  și direcția Newton în acest caz nu există. Observăm că pentru  $x_0 = -1$  metoda Newton va rămâne în același punct. Pe de altă parte, pentru  $x_0 = 0$  Hessiana nu este inversabilă, iar metoda Newton standard nu poate fi aplicată. Pentru  $x_0 = -2$  avem  $x_1 = -2 - 15/4 = -23/4$ , iar din expresia direcției deducem că metoda diverge. Observăm că pentru un punct inițial suficient de aproape de punctul de optim, e.g.  $x_0 = 1.3$ , metoda Newton converge.

**Problema 7.** Fie funcția  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ , definită de  $f(x) = x_1^4 + x_1 x_2 + (1 + x_2)^2$ . Să se descrie performanțele metodei Newton aplicată problemei:

$$\min_{x \in \mathbb{R}^2} f(x),$$

pornind din punctul inițial  $x_0 = [0 \ 0]^T$ .

*Rezolvare.* Calculăm expresiile gradientului și Hessienei:

$$\nabla f(x) = \begin{bmatrix} 4x_1^3 + x_2 \\ x_1 + 2(x_2 + 1) \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} 12x_1^2 & 1 \\ 1 & 2 \end{bmatrix}$$

și evaluând aceste expresii în  $x_0$  avem:

$$\nabla f(x^0) = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \nabla^2 f(x^0) = \begin{bmatrix} 0 & 1 \\ 1 & 2 \end{bmatrix}, \quad (\nabla^2 f(x^0))^{-1} = \begin{bmatrix} -2 & 1 \\ 1 & 0 \end{bmatrix}.$$

Astfel, direcția Newton pentru punctul  $x_0$  va fi:

$$d_0 = -(\nabla^2 f(x_0))^{-1} \nabla f(x_0) = \begin{bmatrix} -2 \\ 0 \end{bmatrix},$$

iar  $\nabla f(x_0)^T d_0 = 0$ . Observăm că aceeași egalitate este valabilă de asemenea pentru  $-d_0$ . Astfel,  $d_0$  nu este direcție de descreștere. În plus, observăm că  $f(x_0) = 1$ , iar pentru  $x_1 = x_0 + d_0 = [-2 \ 0]^T$ , vom avea  $f(x_1) = 17$ , iar pentru  $x_1 = x_0 - d_0$  vom avea tot  $f(x_1) = 17$ .

**Problema 8.** O problemă fundamentală din domeniul prelucrării semnalelor o reprezintă recuperarea unui semnal  $x$  dintr-unul corupt  $y$  (fiind semnalul adevărat  $x$  combinat cu zgomot). De cele mai multe ori, problema este abordată prin aproximarea cât mai fidelă a semnalului adevărat prin intermediul rezolvării următoarei probleme de optimizare:

$$\min_{x \in \mathbb{R}^n} \|x - y\|_2 + \mu \sum_{i=1}^{n-1} |x_{i+1} - x_i|,$$

Observăm că deși primul termen ce denotă distanța Euclidiană dintre semnalul adevărat  $x$  și cel corupt  $y$  este suficient pentru a găsi o aproximare relativ fidelă, se adaugă un termen de regularizare descris de suma diferențelor dintre elementele consecutive ale semnalului  $x$ . Acest termen de regularizare are scopul de a asigura găsirea unei aproximări cât mai netede, fără variații bruște ale componentelor. Observăm că funcția obiectiv a problemei anterioare este nediferențiabilă.

- (i) Să se determine o aproximare a problemei de optimizare precedente, cu funcția obiectiv continuu diferentiabilă;
- (ii) Să se calculeze forma explicită a gradientului și Hessienei corespunzătoare noii funcții obiectiv de la punctul a), și să se aplice un pas al metodei Newton.

*Rezolvare.* (i) O aproximare netedă (*smooth*) a problemei din enunț este dată de:

$$\min_{x \in \mathbb{R}^n} f(x) \quad \left( = \|x - y\|_2^2 + \mu \sum_{i=1}^{n-1} \left( \sqrt{\epsilon^2 + (x_{i+1} - x_i)^2} - \epsilon \right) \right),$$

unde  $\epsilon > 0$  este suficient de mic.

(ii) Determinăm forma explicită a primului pas din metoda Newton. Reamintim direcția Newton:  $d_N = -[\nabla^2 f(x)]^{-1} \nabla f(x)$ . Notând  $\phi_\epsilon(x) = \mu \sum_{i=1}^{n-1} \left( \sqrt{\epsilon^2 + (x_{i+1} - x_i)^2} - \epsilon \right)$ , se observă că gradientul funcției obiectiv a problemei de la punctul a) este:

$$\nabla f(x) = 2(x - y) + \mu \nabla \phi_\epsilon(x).$$

Mai departe, Hessiana aceleiași funcții este dată de:  $\nabla^2 f(x) = 2I_n + \mu \nabla^2 \phi_\epsilon(x)$ . În concluzie, dificultatea se reduce la determinarea formei explicite a gradientului și matricei Hessiene corespunzătoare funcției  $\phi_\epsilon$ .

Pentru o expunere simplificată, notăm  $g(u) = \mu \sum_{i=1}^{n-1} \left( \sqrt{\epsilon^2 + u_i^2} - \epsilon \right)$ , și observăm că  $\phi_\epsilon(x) = g(Ax)$ , unde  $A \in \mathbb{R}^{(n-1) \times n}$  dată de:

$$A = \begin{bmatrix} -1 & 1 & 0 & 0 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & -1 & 1 \end{bmatrix}.$$

Precizăm că sunt suficiente expresiile derivatelor funcției  $g$  pentru a le determina pe cele ale funcției  $\phi_\epsilon$ . Astfel, determinăm forma explicită a componentelor acestora:

$$\nabla_i g(u) = \frac{u_i}{\sqrt{\epsilon^2 + u_i^2}} \quad \nabla_{ii}^2 g(u) = \frac{\epsilon^2}{\sqrt{\epsilon^2 + u_i^2}^3}.$$

Deoarece funcția  $g$  este separabilă, Hessiana acesteia este matrice diagonală. În final avem:

$$\nabla f(x) = 2(x - y) + \mu A^T \nabla g(Ax) \quad \nabla^2 f(x) = 2I_n + \mu A^T \nabla^2 g(Ax) A$$

și observăm că matricea  $\nabla^2 f(x)$  este superior bidiagonală. Direcția Newton este dată de soluția sistemului superior bidiagonal:

$$\nabla^2 f(x) d_N = -\nabla f(x),$$

ce se rezolvă în  $\mathcal{O}(n)$  operații.

## 4.4 Probleme propuse

**Problema 1.** Pentru următoarele două probleme, să se determine punctele de optim și să se implementeze primii trei pași ai metodei Newton standard, i.e. cu pas constant  $\alpha = 1$ :

- (i)  $\min_{x \in \mathbb{R}} \ln(e^x + e^{-x})$ , pornind din  $x_0 = 1$  și  $x_0 = 1.1$
- (ii)  $\min_{x \in \mathbb{R}} -\ln x + x$ , pornind din  $x_0 = 3$

Ce se observă după primii trei pași?

**Problema 2.** Fie următoarea problemă de optimizare:

$$\min_{x \in \mathbb{R}^2} x_1^2 + 100x_2^2$$

Să se implementeze metoda BFGS cu pas optim la fiecare iterație, pornind din punctul inițial  $x^0 = [1 \ 1]^T$  și matricea inițială  $H_0 = I_2$ . În câți pași converge metoda la punctul de optim?

**Problema 3.** Să se implementeze primii doi pași ai metodei DFP (Davidon-Fletcher-Powell) pentru următoarea problemă:

$$\min_{x \in \mathbb{R}^2} x_1^2 + 3x_2^2 + e^{1+x_1^2+x_2^2}$$

pornind din punctul inițial  $x = [1 \ 1]^T$  și matricea inițială  $H_0 = I_2$ .

**Problema 4.** Pentru problema din exercițiul 2 din cadrul problemelor propuse, să se implementeze primele trei iterații ale algoritmului Fletcher-Reeves de gradienti conjugati pornind din același punct inițial și să se compare iterațiile acesteia cu cele ale metodei BFGS.

**Problema 5.** Fie o matrice  $B \in \mathbb{R}^{n \times n}$  simetrică și doi vectori  $s, y \in \mathbb{R}^n$ . Fie  $B_0 = B$  și șirul de matrice:

$$\hat{B}_k = B_k + \frac{(y - B_k s)s^T}{s^T s}, \quad B_{k+1} = \frac{\hat{B}_k + \hat{B}_k^T}{2},$$

pentru orice  $k > 0$ . Arătați că șirul  $B_k$  converge la o matrice  $B_+$  definită astfel:

$$B_+ = B + \frac{(y - Bs)s^T + s(y - Bs)^T}{s^T s} - \frac{(y - Bs)^T s}{(s^T s)^2} s s^T.$$

**Problema 6.** Fie funcția  $f$  convexă că Hessiana  $\nabla^2 f(x)$  bloc diagonală. Cum putem exploata această structură în calcularea direcției Newton? Ce semnificație are pentru  $f$ ?

**Problema 7.** Pentru următoarele funcții obiectiv, să se determine expresia lungimii unui pas selectat ideal  $\alpha^* = \min_{\alpha \geq 0} f(x + \alpha d)$ :

$$(i) \ f(x) = - \sum_{i=1}^m \log(b - a_i^T x). \quad (ii) \ f(x) = \log \left( \sum_{i=1}^m e^{(a_i^T x + b_i)} \right).$$

**Problema 8.** Descrieți o metodă eficientă de calcul al direcției Newton corespunzătoare funcției:

$$f(x) = - \sum_{i=1}^m \log(-x^T Q_i x - b_i^T x - c_i),$$

unde  $m \ll n$ , iar matricele  $Q_i \in \mathbb{R}^{n \times n}$ ,  $Q_i \succ 0$  au dimensiuni mari și structură rară.

**Problema 9.** Fie vectorul  $y \in \mathbb{R}^n$  vector cunoscut, funcția  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  este definită de:

$$f(x) = \sum_{i=1}^n g(x_i - y_i) + \lambda \sum_{i=1}^{n-1} (x_{i+1} - x_i)^2$$

unde  $g : \mathbb{R} \rightarrow \mathbb{R}$  este o funcție convexă și de două ori diferențiabilă,  $\lambda > 0$ . Să se determine expresia Hessienei  $\nabla^2 f(x)$ . Care este numărul de operații necesar pentru calcularea direcției Newton în orice punct  $x$ ?

**Problema 10.** Considerăm următoarea problemă de optimizare neconstrânsă:

$$\min_{x \in \mathbb{R}^n} f(x) \quad (= \sum_{i=1}^p g_i(A_i x - b_i))$$

unde  $A_i \in \mathbb{R}^{m_i \times n}$ ,  $b_i \in \mathbb{R}^{m_i}$ ,  $m_i \ll n$ , iar  $g_i : \mathbb{R}^{m_i} \rightarrow \mathbb{R}$  funcții convexe și de două ori diferențiabile. Știind că  $A_i$  au structură rară, calculați expresia Hessienei și a gradientului lui  $f$  și discutați o modalitate eficientă de implementare a metodei Newton pentru această problemă.

**Problema 11.** Fie funcția  $f(x) = 20 + x_1^2 - 10\cos(2\pi x_1) + x_2^2 - 10\cos(2\pi x_2)$ . Să se implementeze metoda cvasi-Newton (BFGS) cu alegerea ideală a dimensiunii pasului pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^2} f(x). \quad (4.5)$$

Să se rezolve problema (4.5) prin apelarea funcției `fminunc` și sa se compare rezultatele obținute.