

Capitolul 2

Probleme de optimizare convexă

2.1 Preliminarii

Fie problema de optimizare,

$$\begin{aligned} \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l.: } g_i(x) \leq 0 \quad \forall i = 1, \dots, m \\ Ax = b. \end{aligned} \tag{2.1}$$

Dacă funcția obiectiv f și funcțiile ce definesc constrângerile de inegalitate g_i sunt convexe atunci problema se numește *problemă de optimizare convexă*. Convexitatea deține un rol crucial în optimizare, deoarece problemele cu această proprietate prezintă trăsături teoretice foarte bune (e.g., punctele de optim locale sunt, de asemenea, puncte de optim globale); și ceea ce este mai important, pot fi rezolvate numeric în mod eficient, ceea ce nu este valabil pentru problemele neconvexe. Vom studia mai departe noțiunile de *funcție convexă* și *mulțime convexă* pentru a sublinia proprietățile remarcabile ale problemelor convexe.

2.1.1 Mulțimi convexe

Pentru o expunere clară și concisă, introducem următoarele definiții:

Definiția 1. Multimea $S \subseteq \mathbb{R}^n$ se numește *convexă* dacă pentru oricare două puncte $x_1, x_2 \in S$ și un scalar $\alpha \in [0, 1]$ avem $\alpha x_1 + (1 - \alpha)x_2 \in S$,

i.e. segmentul generat de oricare două puncte din S este inclus în S (Fig. 2.1).




Figura 2.1: Exemplu de mulțime convexă (stânga) și mulțime neconvexă (dreapta).

Exemplul 11. Fie mulțimea $\mathcal{L}_n = \left\{ \begin{bmatrix} x \\ t \end{bmatrix} \in \mathbb{R}^{n+1} : \|x\| \leq t \right\}$, denumită și *conul Lorentz* sau conul de înghețată. Să se traseze graficul acestei mulțimi în Matlab pentru $n = 2$.

Rezolvare. Figura conului (Fig. 2.2) poate fi trasată de următoarea secvență de cod:

```
function create_cone
[y1,y2]=meshgrid(-1:0.01:1,-1:0.01:1);
y3=sqrt(y1.^2+y2.^2); dom=[y3>1];
z3=y3; z3(dom)=inf;
figure(1);
hold on;
surf(y1,y2,z3); set(gca,'FontSize',15);
hold off;
end
```




Figura 2.2: Con de ordinul II (con Lorentz) în \mathbb{R}^3 pentru $n = 2$.

Studiul mulțimilor convexe și al proprietăților acestora facilitează analiza mulțimilor fezabile aferente problemelor de tipul (2.1) și a șirurilor generate de algoritmi cu restricții la aceste mulțimi. În continuare vom introduce și analiza noțiunea de funcție convexă.

2.1.2 Funcții convexe

Definiția 2. Funcția $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se numește *convexă* dacă domeniul său efectiv $\text{dom} f$ este o mulțime convexă și dacă următoarea inegalitate:

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2), \quad (2.2)$$

este satisfăcută pentru orice $x_1, x_2 \in \text{dom} f$ și $\alpha \in [0, 1]$.




Figura 2.3: Exemplu de funcție convexă $f(x) = x^2$.

Inegalitatea (2.2) se poate generaliza la un număr p de puncte, purtând numele de *inegalitatea lui Jensen*: f este o funcție convexă dacă și numai dacă:

$$f\left(\sum_{i=1}^p \alpha_i x_i\right) \leq \sum_{i=1}^p \alpha_i f(x_i)$$

pentru orice $x_i \in \text{dom} f$ și $\alpha_i \in [0, 1]$, cu $\sum_{i=1}^p \alpha_i = 1$.

Interpretarea geometrică a convexității este foarte simplă (Fig. 2.3). Pentru o funcție convexă, fie două puncte din domeniul său $x, y \in \text{dom} f$, atunci valorile funcției evaluate în punctele din intervalul $[x, y]$ sunt mai mici sau egale decât cele aflate pe segmentul cu capetele $(x, f(x))$ și $(y, f(y))$.

Remarca 1. O funcție este convexă dacă și numai dacă restricția domeniului său la o dreaptă (care intersectează domeniul) este de asemenea, convexă. Cu alte cuvinte, f este convexă dacă și numai dacă oricare ar fi $x \in \text{dom} f$ și o direcție d , funcția $g(\alpha) = f(x + \alpha d)$ este convexă pe domeniul $\{\alpha \in \mathbb{R} : x + \alpha d \in \text{dom} f\}$. Această proprietate este foarte utilă în problemele ce implică teste de convexitate ale funcțiilor.

Pentru a sublinia legătura dintre noțiunile introduse anterior, facem următoarea observație: orice mulțime M definită ca mulțimea subnivel a unei anumite funcții f , i.e. $M = \{x \in \mathbb{R}^n : f(x) \leq c\}$, unde c este o constantă, este convexă dacă și numai dacă funcția f este convexă (pentru demonstrație vezi [1]).

Exemplul 12. Fie funcția convexă $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, definită de $f(x) = \frac{1}{2}x^T \begin{bmatrix} 2 & -1 \\ -1 & 0.5 \end{bmatrix} x + [-0.5 \ 1]x$. Să se traseze graficul funcției în Matlab.

Rezolvare. Graficul funcției (Fig. 2.4) este generat de următoarea secvență de cod (unde am folosit funcția *gradient*(z) pentru a descrie culoarea, graduală de-a lungul axei z , graficului rezultat):

```
function create_parab
[x,y] = meshgrid([-10:.2:10]);
z=x.^2+0.25*(y.^2)-x.*y-0.5*x+y;
surf(x,y,z,gradient(z))
end
```

2.2 Pachet CVX

În această subsecțiune expunem o scurtă prezentare a pachetului de optimizare CVX. CVX reprezintă un sistem de modelare a problemelor de optimizare convexă pe baza limbajului Matlab. CVX realizează transformarea comenzilor Matlab într-un limbaj de modelare, cu




Figura 2.4: Graficul funcției pătratice
 $f(x) = x_1^2 + 1/4x_2^2 - x_1x_2 - 1/2x_1 + x_2$.

posibilitatea de declarare a constrângerilor și funcției obiectiv prin intermediul sintaxei Matlab standard.

De exemplu, considerăm următorul model de optimizare convexă:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} & \|Ax - b\|_2 \\ \text{s.l.: } & Cx = d, \|x\|_\infty \leq 1. \end{aligned}$$

Următoarea secvență de cod generează și rezolvă o instanță aleatorie a acestui model:

```
m = 10; n = 8; p = 2;
A = randn(m,n); b = randn(m,1);
C = randn(p,n); d = randn(p,1);
cvx_begin
    variable x(n)
    minimize(norm(A*x - b, 2))
    subject to
        C*x == d
        norm(x, Inf) <= 1
cvx_end
```

2.2.1 Instalare

Un scurt ghid de instalare presupune următorii pași:

se descarcă arhiva de la adresa : <http://cvxr.com/cvx/>, fișier .zip sau .tar.gz;

se dezarchivează într-un director dorit (diferit de directorul toolbox al Matlab-ului);

se pornește Matlab-ul; se comută directorul curent în directorul unde am realizat dezarhivarea și se execută în consolă comanda `cvx_setup`.

Remarca 2. În unele cazuri (de cele mai multe ori în Linux) este nevoie de crearea sau modificarea fișierului `startup.m` ce elimină necesitatea ca utilizatorul să introducă comanda `cvx_setup` la fiecare pornire a Matlab-ului.

2.2.2 Elemente de bază

Dacă instalarea este realizată cu succes, începem prin a preciza că orice program CVX se scrie în interiorul unei funcții Matlab. Pentru a diferenția conținutul codului CVX de restul programului Matlab, programele CVX se delimitează cu comenzile `cvx_begin` și `cvx_end`. Valorile variabilelor create în porțiunea de cod Matlab se pot folosi ca parametri în problemele de optimizare rezolvate cu CVX. La începutul oricărui program CVX se definesc variabilele de decizie și dimensiunile acestora, e.g.:

```
m = 10; n = 8; A = randn(m,n); b = randn(m,1);
cvx_begin
    variable x(n)
    minimize( norm(A*x-b) )
cvx_end
```

În acest exemplu, variabila de decizie este vectorul x din \mathbb{R}^n , iar matricea A și vectorul b reprezintă variabile Matlab ce sunt utilizate ca parametri în cadrul CVX. Variabilele CVX se declară folosind comanda `variable` și specificarea dimensiunii variabilei, înainte de a se utiliza în constrângeri sau în expresia funcției obiectiv. Sintaxa declarării unei variabile poate fi una din următoarele forme:

```
variable x(10)    variable Y(20,10)    variable Z(5,5,5).
```

Sunt disponibile o varietate de opțiuni adiționale pentru precizarea structurii matriceale, în cazul în care variabila de decizie este de tip matrice cu proprietăți speciale (simetrică, Toeplitz) e.g.:

```
variable Y(50,50) symmetric
variable Z(100,100) hermitian toeplitz.
```

Pentru lista întreagă a opțiunilor se poate consulta adresa:

`http://cvxr.com/cvx/doc/basics.html`.

Declararea *funcției obiectiv* a problemei de optimizare necesită precizarea tipului de problemă (e.g. minimizare, maximizare) prin intermediul cuvintelor cheie `minimize` și `maximize`, e.g.

```
minimize( norm( x, 1 ) )
maximize( geo_mean( x ) ).
```

Precizăm că este imperativ ca funcția obiectiv să fie convexă când folosim `minimize` și concavă când folosim `maximize`. În caz contrar, pachetul CVX va furniza un mesaj de eroare corespunzător. *Constrângerile* suportate de modelele CVX sunt cele de egalitate (liniare) impuse prin operatorul `==` și de inegalitate impuse de operatorii `<=` și `>=`. Pentru constrângeri de tip box (lanț de inegalități) este disponibilă sintaxa `l<=x<=u`.

2.3 Probleme rezolvate de laborator

Exemplul 13. Să se determine bila de rază maximă (i.e. centrul și raza ei) din spațiul Euclidian bidimensional, ce poate fi înscrisă într-un poliedru descris de inegalități liniare (Fig. 2.5).

Rezolvare. În cazul general, fiind dat setul de inegalități liniare $a_i^T x \leq b_i$, formularea problemei în termeni de optimizare este dată de:

$$\begin{aligned} \max_{x \in \mathbb{R}^n, r \in \mathbb{R}} \quad & r \\ \text{s.l.:} \quad & a_i^T x + r \|a_i\|_2 \leq b_i \quad \forall i = 1, \dots, n, \end{aligned}$$

unde r reprezintă raza bilei, iar x centrul acesteia. Alegând datele inegalităților liniare, coordonatele centrului și raza bilei dorite sunt generate de următoarea secvență de program:

```
% Generare date de intrare
a1 = [ 2; 1]; a2 = [ 2; -1]; a3 = [-1; 2];
a4 = [-1; -2]; b = ones(4,1);
% Crearea si rezolvarea problemei de optimizare
cvx_begin
    variable r(1)
```




Figura 2.5: Bila de rază maximă înscrisă într-un poliedru.

```

variable x_c(2)
maximize ( r )
a1'*x_c + r*norm(a1,2) <= b(1);
a2'*x_c + r*norm(a2,2) <= b(2);
a3'*x_c + r*norm(a3,2) <= b(3);
a4'*x_c + r*norm(a4,2) <= b(4);
cvx_end

% Generare figura
x = linspace(-2,2);
theta = 0:pi/100:2*pi;
plot( x, -x*a1(1)./a1(2) + b(1)./a1(2), 'b-');
hold on
plot( x, -x*a2(1)./a2(2) + b(2)./a2(2), 'b-');
plot( x, -x*a3(1)./a3(2) + b(3)./a3(2), 'b-');
plot( x, -x*a4(1)./a4(2) + b(4)./a4(2), 'b-');
plot( x_c(1) + r*cos(theta), x_c(2) + r*sin(theta), 'r');
plot(x_c(1),x_c(2),'k+'); xlabel('x_1'); ylabel('x_2');
title('Bila de raza maxima inscrisa intr-un poliedru 2D');
axis([-1 1 -1 1]); axis equal;

```

Exemplul 14. Determinați filtrul FIR cu cel mai apropiat comportament de cel al unei funcții de transfer date $H_d(\omega)$ (e.g. $H_d(\omega) = e^{-j\omega D}$). Să se realizeze proiectarea filtrului prin intermediul minimizării erorii absolute maxime (în norma infinit).

Rezolvare. Formularea problemei precedente în termeni de optimizare conduce la rezolvarea următoarei probleme:

$$\min_H \max_{\omega} |H(\omega) - H_d(\omega)|, \quad (2.3)$$

unde H este funcția răspunsului în frecvență, iar variabila de decizie are rolul răspunsului la impuls. O aproximare convenabilă a problemei anterioare presupune extragerea unui set finit m de frecvențe ω_i , cu $i = 1, \dots, m$, și definirea unei matrice A :

$$A = \begin{bmatrix} 1 & e^{-j\omega_1} & e^{-2j\omega_1} & \dots & e^{-nj\omega_1} \\ 1 & e^{-j\omega_2} & e^{-2j\omega_2} & \dots & e^{-nj\omega_2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & e^{-j\omega_m} & e^{-2j\omega_m} & \dots & e^{-nj\omega_m} \end{bmatrix}$$

rezultând o aproximare a problemei (2.3), i.e.

$$\min_{x \in \mathbb{R}^n} \max_{1 \leq i \leq m} |A_i x - H_d(\omega_i)|, \quad (2.4)$$

unde A_i reprezintă linia i a matricei A .

Mai departe, prezentăm secvența de cod ce rezolvă problema de optimizare (2.4) și determinăm aproximarea optimă a funcției de transfer $H_d(\omega) = e^{-j\omega D}$ (reprezentată în Fig. 2.6):




Figura 2.6: Aproximarea optimă în sens Chebyshev a funcției de transfer $H_d(\omega) = e^{-j\omega D}$.

```
n = 20; m = 15*n;
w = linspace(0,pi,m)'; % omega
% Construim un raspuns in frecventa dorit
```

```

D = 8.25;                % valoare intarziere
Hdes = exp(-j*D*w);      % raspuns in frecventa dorit

% Filtru Gaussian cu faza liniara (decomentati liniile
% de mai jos pentru proiectare)
% var = 0.05;
% Hdes = 1/(sqrt(2*pi*var))*exp(-(w-pi/2).^2/(2*var));
% Hdes = Hdes.*exp(-j*n/2*w);

% Rezolvam problema minimax de proiectare a filtrului
% A reprezinta matricea folosita la calculul
% raspunsului in frecventa
% A(w,:) = [1 exp(-j*w) exp(-j*2*w) ... exp(-j*n*w)]
A = exp( -j*kron(w,[0:n-1]) );

% formularea optimala a filtrului Chebyshev
cvx_begin
    variable h(n,1)
    minimize( max( abs( A*h - Hdes ) ) )
cvx_end

% verificam daca problema a fost rezolvata cu succes
disp(['Problem is ' cvx_status])
if ~strfind(cvx_status,'Solved')
    h = [];
end

% Generam figurile aferente filtrului
figure(1); stem([0:n-1],h); xlabel('n'); ylabel('h(n)');

% figura raspunsului in frecventa
H = [exp(-j*kron(w,[0:n-1]))]*h;
figure(2)
% magnitudine
subplot(2,1,1);
plot(w,20*log10(abs(H)),w,20*log10(abs(Hdes)),'--');
xlabel('w'); ylabel('mag H in dB'); axis([0 pi -30 10]);
legend('optimizat','dorit','Location','SouthEast')
% faza

```

```
subplot(2,1,2); plot(w,angle(H));
axis([0,pi,-pi,pi]); xlabel('w'), ylabel('faza H(w)');
```

2.4 Probleme rezolvate de seminar

2.4.1 Mulțimi și funcții convexe

Problema 1. Fie mulțimea S descrisă de:

$$\begin{aligned} S &= \{x \in \mathbb{R}^n : a_i^T x = b_i, \ c_j^T x \leq d_j, \ i = 1, \dots, m, j = 1, \dots, p\} \\ &= \{x \in \mathbb{R}^n : Ax = b, \ Cx \leq d\}. \end{aligned}$$

Să se demonstreze că mulțimea este convexă (mulțimile definite de egalități și inegalități liniare, cum este cea din enunț, se numesc *poliedre*).

Rezolvare. Se arată că pentru orice $x_1, x_2 \in S$ și $\alpha \in [0, 1]$ rezultă $\alpha x_1 + (1 - \alpha)x_2 \in S$. Dacă $x_1, x_2 \in S$ atunci avem:

$$\begin{cases} Ax_1 = b, & Cx_1 \leq d \\ Ax_2 = b, & Cx_2 \leq d. \end{cases}$$

Notând $x_\alpha = \alpha x_1 + (1 - \alpha)x_2$, putem finaliza demonstrația prin următoarea observație:

$$\begin{aligned} Ax_\alpha &= \alpha Ax_1 + (1 - \alpha)Ax_2 = \alpha b + (1 - \alpha)b = b \\ Cx_\alpha &= \alpha Cx_1 + (1 - \alpha)Cx_2 \leq \alpha d + (1 - \alpha)d = d. \end{aligned}$$

În acest fel am demonstrat că mulțimea definită anterior este convexă.

Problema 2. Să se demonstreze că următoarele mulțimi se pot defini sub forma unor poliedre:

(i) $S_1 = \{x \in \mathbb{R}^n : x \geq 0, \|x\|_1 = 1\}$

(ii) $S_2 = \{x \in \mathbb{R}^n : \|x\|_\infty \leq 1\}$

(iii) $S_3 = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\}.$

Rezolvare. : (i) În cazul mulțimii S_1 observăm următoarele echivalențe:

$$\begin{aligned} S_1 &= \left\{ x \in \mathbb{R}^n : x \geq 0, \sum_{i=1}^n x_i = 1 \right\} = \left\{ x \in \mathbb{R}^n : -x \leq 0, \sum_{i=1}^n x_i = 1 \right\} \\ &= \{x \in \mathbb{R}^n : -I_n x \leq 0, [1 \dots 1]x = 1\}, \end{aligned}$$

unde I_n reprezintă matricea identitate de ordin n . Ultima formulare denotă forma poliedrală a mulțimii S_1 .

(ii) De asemenea, în cazul mulțimii S_2 , urmând același raționament:

$$\begin{aligned} S_2 &= \left\{ x \in \mathbb{R}^n : \max_{1 \leq i \leq n} |x_i| \leq 1 \right\} = \{x \in \mathbb{R}^n : |x_i| \leq 1, \forall i = 1, \dots, n\} \\ &= \{x \in \mathbb{R}^n : -1 \leq x_i \leq 1 \forall i = 1, \dots, n\} \\ &= \{x \in \mathbb{R}^n : -x_i \leq 1, x_i \leq 1, \forall i = 1, \dots, n\} \\ &= \left\{ x \in \mathbb{R}^n : \begin{bmatrix} I_n \\ -I_n \end{bmatrix} x \leq \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right\}, \end{aligned}$$

obținem o formă poliedrală.

(iii) Pentru a determina forma poliedrică a mulțimii S_3 definim o mulțime poliedrică auxiliară:

$$Q = \left\{ [x^T \ t^T]^T \in \mathbb{R}^{2n} : \sum_{i=1}^n t_i = 1, |x_i| \leq t_i \right\}.$$

Mai departe, definim proiecția unei mulțimi poliedrice pe un subspațiu de dimensiuni reduse și folosim această noțiune pentru a studia mulțimea S_3 .

Definiția 3. Fie mulțimea $P = \{x \in \mathbb{R}^{n_1}, y \in \mathbb{R}^{n_2} : Ax + By \leq b\}$, unde $A \in \mathbb{R}^{m \times n_1}, B \in \mathbb{R}^{m \times n_2}, b \in \mathbb{R}^m$. *Proiecția* mulțimii P pe subspațiul variabilelor x este dată de:

$$P_x = \{x \in \mathbb{R}^{n_1} : \exists y \in \mathbb{R}^{n_2}, [x^T \ y^T]^T \in P\}.$$

Proiecția mulțimii Q pe subspațiul variabilelor x conduce la următoarea serie de echivalențe:

$$\begin{aligned} Q_x &= \{x \in \mathbb{R}^n : \exists t \in \mathbb{R}^n \text{ a.î. } \sum_{i=1}^n t_i = 1, |x_i| \leq t_i\} \\ &= \{x \in \mathbb{R}^n : \sum_{i=1}^n |x_i| \leq 1\} = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\} = S_3. \end{aligned}$$

Ținând cont că proiecția oricărei mulțimi poliedrice este o mulțime poliedrică, concluzionăm că mulțimea S_3 este de tip poliedric.

Problema 3. Fie mulțimile:

$$(i) \mathcal{L}^n = \left\{ \begin{bmatrix} x \\ t \end{bmatrix} \in \mathbb{R}^{n+1} : \|x\| \leq t \right\} \text{ numit și con Lorentz sau con de ordinul II;}$$

$$(ii) \mathcal{S}_+^n = \{X \in \mathcal{S}^n : X \succeq 0\} \text{ conul semidefinit.}$$

Să se demonstreze că mulțimile precedente sunt conuri auto-duale.

Rezolvare: (i) Din definiția conului dual avem:

$$\mathcal{L}_n^* = \{y \in \mathbb{R}^n : \langle x, y \rangle \geq 0 \forall x \in \mathcal{L}_n\}.$$

Problema se reduce la a demonstra că $\mathcal{L}_n^* = \mathcal{L}_n$, ceea ce este echivalent cu satisfacerea simultană a incluziunilor: $\mathcal{L}_n^* \subseteq \mathcal{L}_n$ și $\mathcal{L}_n \subseteq \mathcal{L}_n^*$.

Arătăm acum prima incluziune. Fie $y = \begin{bmatrix} y_1 \\ v \end{bmatrix} \in \mathcal{L}_n^*$, atunci pentru orice $x = \begin{bmatrix} x_1 \\ t \end{bmatrix} \in \mathcal{L}_n$ avem:

$$\langle x, y \rangle = y_1^T x_1 + vt \geq 0. \quad (2.5)$$

Știind că $x \in \mathcal{L}_n$ atunci $\|x\| \leq t$. Rămâne să demonstrăm că $\|y\| \leq v$. Din ipoteza că (2.5) are loc pentru orice vector $x \in \mathcal{L}_n$, atunci inegalitatea este satisfăcută, de asemenea, pentru un x ales. Alegând $x = \begin{bmatrix} x_1 \\ t \end{bmatrix} = \begin{bmatrix} -\frac{y_1}{\|y_1\|} \\ 1 \end{bmatrix}$ și înlocuind în (2.5) obținem:

$$-\frac{y_1^T y_1}{\|y_1\|} + v = -\|y_1\| + v \geq 0,$$

din care rezultă prima incluziune.

Pentru a doua incluziune, fie $y = \begin{bmatrix} y_1 \\ v \end{bmatrix} \in \mathcal{L}_n, x = \begin{bmatrix} x_1 \\ t \end{bmatrix} \in \mathcal{L}_n^*$. Din inegalitatea Cauchy-Schwartz $|\langle x, y \rangle| \leq \|x\| \|y\|$ rezultă:

$$y_1^T x_1 + vt > -\|y_1\| \|x_1\| + vt \geq -vt + vt = 0,$$

unde în a doua inegalitate am utilizat ipoteza că $x, y \in \mathcal{L}_n$. În concluzie, pentru orice $y \in \mathcal{L}_n$ avem că $y \in \mathcal{L}_n^*$.

(ii) În mod similar, arătăm prin dublă incluziune că $\mathcal{S}_+^n = \mathcal{S}_+^{n*}$. Fie $Y \in \mathcal{S}_+^{n*}$, atunci $\text{Tr}(YX) \geq 0$. Din următoarele relații:

$$x^T Y x = \text{Tr}(x^T Y x) = \text{Tr}(Y x x^T) = \text{Tr}(YX) \geq 0,$$

se deduce $Y \in \mathcal{S}_+^n$. Pentru a doua incluziune, presupunem Y, X matrice pozitiv semidefinite. Remarcăm următoarea relație:

$$\text{Tr}(YX) = \text{Tr}(YV^T \Delta V) = \text{Tr}(VYV^T \Delta) \geq 0, \quad (2.6)$$

în care am folosit descompunerea valorilor proprii corespunzătoare matricei X și proprietatea de permutare a funcției matriceale $\text{Tr}(\cdot)$. În concluzie, $Y \in \mathcal{S}_+^{n*}$ datorită relației (2.6), de unde reiese a doua incluziune.

Problema 4. Să se demonstreze că următoarele funcții sunt convexe pe mulțimile specificate:

- (i) $f(x) = -\log x$, $\text{dom} f = (0, \infty)$.
- (ii) $f(x) = \frac{1}{2}x^T Q x + q^T x + r$, $\text{dom} f = \mathbb{R}^n, Q \succeq 0$.
- (iii) $f(x, t) = \frac{x^T x}{t}$, $\text{dom} f = \mathbb{R}^n \times (0, \infty)$.
- (iv) $f(x) = \|Ax - b\|$, $A \in \mathbb{R}^{m \times n}$, $\text{dom} f = \mathbb{R}^n$.
- (v) $f(X) = -\log \det X$, $\text{dom} f = \mathcal{S}_{++}^n$.

Rezolvare: (i) Observăm că funcția $f(x) = -\log x$ satisface condițiile de ordinul II ale convexității:

$$f''(x) = \frac{1}{x^2} > 0 \quad \forall x > 0.$$

(ii) Hessiana funcției $f(x) = \frac{1}{2}x^T Q x + q^T x + r$ este dată de $\nabla^2 f(x) = Q$. Observăm că funcția este convexă deoarece matricea $Q \succeq 0$ (este pozitiv semidefinită).

(iii) În aceeași manieră arătăm că funcția $f(x, t) = \frac{x^T x}{t}$ este convexă pe domeniul $\mathbb{R}^n \times (0, \infty]$. Din definiția Hessienei rezultă:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{2}{t} I_n & -\frac{2x}{t^2} \\ -\frac{2x^T}{t^2} & \frac{2x^T x}{t^3} \end{bmatrix},$$

unde cu I_n am notat matricea identitate de ordin n . Pentru a determina dacă funcția îndeplinește condițiile de ordinul II ale convexității observăm

că:

$$\begin{aligned}
[u^T v^T] \nabla^2 f(x) \begin{bmatrix} u \\ v \end{bmatrix} &= [u^T v^T] \begin{bmatrix} \frac{2}{t}u - \frac{2xv}{t^2} \\ -\frac{2x^T u}{t^2} + \frac{2x^T xv}{t^3} \end{bmatrix} \\
&= \frac{2}{t}u^T u - \frac{2u^T xv}{t^2} - \frac{2x^T uv}{t^2} + \frac{2x^T xv^2}{t^3} \\
&= \frac{2}{t^3} (t^2 u^T u - 2tu^T xv + x^T xv^2) \\
&= \frac{2}{t^3} \|tu - xv\|^2.
\end{aligned}$$

Ținând cont de domeniul de definiție al funcției, remarcăm că pentru orice vector $\begin{bmatrix} u \\ v \end{bmatrix}$, termenul drept din ultima egalitate este pozitiv. De aici este evidentă proprietatea de pozitiv definire a matricei Hessiane corespunzătoare funcției.

(iv) Deoarece funcția $\|\cdot\|$ este nediferențiabilă în punctul 0, observăm că funcția $f(x) = \|Ax - b\|$ nu este diferențiabilă în punctele x ce satisfac $Ax = b$. Fie două puncte din mulțimea $\text{dom } f$ pentru care $f(x_1) = \|Ax_1 - b\|$, $f(x_2) = \|Ax_2 - b\|$. Pentru a arăta convexitatea funcției f , notăm $x_\alpha = \alpha x_1 + (1 - \alpha)x_2$ și deducem șirul de relații:

$$\begin{aligned}
f(x_\alpha) &= f(\alpha x_1 + (1 - \alpha)x_2) \\
&= \|A(\alpha x_1 + (1 - \alpha)x_2) - b\| \\
&\leq \|\alpha(Ax_1 - b)\| + \|(1 - \alpha)(Ax_2 - b)\| \\
&= \alpha\|Ax_1 - b\| + (1 - \alpha)\|Ax_2 - b\| \\
&= \alpha f(x_1) + (1 - \alpha)f(x_2).
\end{aligned}$$

(v) Fie funcția $f(X) = -\log \det X$, $X \in \mathcal{S}_{++}^n$. Arătăm convexitatea lui f prin intermediul reducerii domeniului acesteia la o dreaptă. Mai exact, folosim următoarea proprietate a funcțiilor convexe: f este convexă dacă funcția scalară ce se obține din restricționarea la o dreaptă este de asemenea convexă (conform Remarca 1). Revenind la funcția matriceală, considerăm matricele $X \in \mathcal{S}_{++}^n$, $D \in \mathcal{S}^n$ și arătăm că funcția scalară $g(t) = f(X + tD)$ este convexă, observând următoarele egalități:

$$\begin{aligned}
g(t) &= -\log \det(X + tD) \\
&= -\log \det(X^{1/2}X^{1/2} + tD) \\
&= -\log \det(X^{1/2}(I_n + tX^{-1/2}DX^{-1/2})X^{1/2})
\end{aligned}$$

$$\begin{aligned}
&= -\log (\det X^{1/2} \det (I_n + tX^{-1/2}DX^{-1/2}) \det X^{1/2}) \\
&= -\log (\det X \det (I_n + tX^{-1/2}DX^{-1/2})) \\
&= -\log \det X - \log \det (I_n + tX^{-1/2}DX^{-1/2}).
\end{aligned}$$

Pe de altă parte, știind că pentru orice matrice $A \in \mathcal{S}^n$, cu spectrul $\Lambda(A) = \{\lambda_1, \dots, \lambda_n\}$, transformarea $B = I_n + tA, t \in \mathbb{R}$, modifică spectrul astfel încât $\Lambda(B) = \{1 + t\lambda_1, \dots, 1 + t\lambda_n\}$ și $\det B = \prod_{i=1}^n (1 + t\lambda_i)$.

Pentru a aplica această proprietate în șirul de relații precedent, notăm $Z = X^{-1/2}DX^{-1/2}$ având spectrul $\Lambda(Z) = \{\mu_1, \dots, \mu_n\}$. Rescriind $g(t)$, rezultă:

$$\begin{aligned}
g(t) &= -\log \det X - \log \prod_{i=1}^n (1 + t\mu_i) \\
&= -\log \det X - \sum_{i=1}^n \log(1 + t\mu_i).
\end{aligned}$$

Mai departe, observăm că funcția $h(t) = -\log(1 + tu)$ din componența celei anterioare, este convexă, deoarece cea de-a două derivată satisface:

$$h''(t) = \frac{u}{(1 + tu)^2} \geq 0 \quad \forall u \in \mathbb{R}.$$

Știind că funcția definită de o sumă de funcții convexe este convexă, ajungem la concluzia că $g(t)$ este convexă în t . Deci, $f(X)$ este convexă.

Problema 5. Fie funcția $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Să se determine funcția conjugată $f^*(y)$ pentru următoarele exemple:

- (i) $f(x) = e^x$ (ii) $f(x) = x \log x$
 (iii) $f(x) = \frac{1}{2}x^T Qx, Q \succ 0$ (iv) $f(x) = \log \sum_{i=1}^n e^{x_i}$.

Rezolvare. Definim funcția conjugată corespunzătoare funcției f :

$$f^*(y) = \max_{x \in \text{dom } f} \langle y, x \rangle - f(x).$$

În primele două cazuri monovariabile (i) și (ii), observăm că funcția obiectiv a problemei de maximizare este concavă pe domeniul funcției

f , de aceea condițiile de optimalitate de ordinul I conduc la următoarele expresii:

$$(i) \ f^*(y) = y \log y - y, \quad (ii) \ f^*(y) = e^{y-1}.$$

(iii) În acest caz, conjugata funcției f are forma $f^*(y) = \max_{x \in \mathbb{R}^n} y^T x - \frac{1}{2} x^T Q x$. Datorită proprietății de convexitate, observăm că soluția problemei de optimizare este dată de $x^* = Q^{-1}y$. Înlocuind în expresia funcției conjugate rezultă $f^*(y) = y^T Q^{-1}y - \frac{1}{2} y^T Q^{-1}y = \frac{1}{2} y^T Q^{-1}y$.

(iv) Condițiile necesare de optimalitate de ordinul I corespunzătoare problemei de maximizare $\max_{x \in \mathbb{R}^n} \langle y, x \rangle - \log \sum_{i=1}^n e^{x_i}$ se reduc la următoarele relații:

$$\frac{e^{x_i^*}}{\sum_{i=1}^n e^{x_i^*}} = y_i, \quad \forall i = 1, \dots, n. \quad (2.7)$$

Observăm că relația (2.7) este satisfăcută și funcția $f^*(y)$ ia valori finite numai în cazul în care argumentul funcției conjugate satisface $\sum_{i=1}^n y_i = 1, y \geq 0$. Presupunând că argumentul y satisface cele două condiții, avem $x_i^* = \log \sum_{i=1}^n e^{x_i^*} + \log y_i$ pentru orice $i = 1, \dots, n$. Substituind în expresia funcției conjugate rezultă:

$$\begin{aligned} \langle y, x^* \rangle - \log \sum_{i=1}^n e^{x_i^*} &= \sum_{i=1}^n y_i \left(\log \sum_{i=1}^n e^{x_i^*} + \log y_i \right) - \log \sum_{i=1}^n e^{x_i^*} \\ &= \sum_{i=1}^n y_i \log y_i + \log \sum_{i=1}^n e^{x_i^*} \left(\sum_{i=1}^n y_i - 1 \right) = \sum_{i=1}^n y_i \log y_i. \end{aligned}$$

În concluzie, funcția conjugată $f^*(y)$ este definită de:

$$f^*(y) = \begin{cases} \sum_{i=1}^n y_i \log y_i, & \text{dacă } \sum_{i=1}^n y_i = 1, y \geq 0, \\ \infty, & \text{altfel.} \end{cases}$$

Problema 6. Să se demonstreze că următoarea problemă de optimizare este convexă:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} f(x) &= x_1^2 + x_2^2 \\ \text{s.l.: } g_1(x) &= \frac{x_1}{1+x_2^2} \leq 0, g_2(x) = e^{x_1+x_2} - 1 \leq 0 \\ h(x) &= (x_1 - x_2 - 1)^2 = 0. \end{aligned}$$

Rezolvare. Pentru a arăta convexitatea problemei din enunț:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} f(x) \\ \text{s.l.: } g_1(x) \leq 0, g_2(x) \leq 0, h(x) = 0. \end{aligned}$$

este suficient să demonstrăm convexitatea funcțiilor f , g_1 și g_2 , și liniaritatea funcției h . Observăm că Hessiana funcției f are forma explicită $\nabla^2 f(x) = I_2 \succ 0$, unde I_2 este matricea identitate de ordinul II. Deci, funcția f este convexă deoarece satisface condiția de convexitate de ordinul II. În cazul funcției g_1 , distingem faptul că inegalitatea $\frac{x_1}{1+x_2^2} \leq 0$ este satisfăcută doar în cazul în care $x_1 \leq 0$. În concluzie, constrângerea $g_1(x) \leq 0$ este echivalentă cu o constrângere liniară (și deci convexă) $x_1 \leq 0$. Pentru inegalitate $g_2(x) \leq 0$, observăm că este echivalentă cu $x_1 + x_2 \leq 0$, i.e. este și aceasta echivalentă cu o constrângere liniară. Similar, pentru egalitatea definită de funcția h , găsim următoarea echivalență între mulțimi:

$$\{x \in \mathbb{R}^2 : h(x) = 0\} = \{x \in \mathbb{R}^2 : x_1 - x_2 = 1\},$$

rezultând o funcție liniară în x . În final, putem rescrie problema sub forma unui QP convex:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} x_1^2 + x_2^2 \\ \text{s.l.: } x_1 \leq 0, x_1 + x_2 \leq 0, x_1 - x_2 = 1. \end{aligned}$$

Problema 7. Să se demonstreze că următoarea problemă de optimizare este convexă:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} f(x) \quad (= -\log(a^T x - b)) \\ \text{s.l.: } g_1(x) = e^{x^T x} - e \leq 0, g_2(x) = (c^T x - d)^2 - 1 \leq 0 \\ h(x) = (x_1 + 2x_2)^4 = 0. \end{aligned}$$

Rezolvare. Pentru a demonstra că o problemă de optimizare este convexă, trebuie să demonstrăm că funcția obiectiv este convexă și mulțimea fezabilă definită de constrângeri este convexă. Pentru funcția $f(x) = -\log(a^T x - b)$ deducem expresia gradientului și a Hessienei:

$$\nabla f(x) = -\frac{1}{a^T x - b}a, \quad \nabla^2 f(x) = \frac{1}{(a^T x - b)^2}aa^T$$

unde avem desigur că $(a^T x - b)^2 > 0$. Dacă notăm $y = a^T x$, observăm că:

$$x^T aa^T x = y^T y = \|y\|_2^2 \geq 0,$$

deci matricea aa^T este pozitiv semidefinită. Drept rezultat, $\nabla^2 f(x) \succeq 0$ peste întregul dom $f = \{x \in \mathbb{R}^n : a^T x - b > 0\}$, i.e. satisface condițiile de convexitate de ordin II și deci funcția obiectiv este convexă. Pentru a arăta că mulțimea constrângerilor este convexă, este suficient să arătăm că funcțiile din constrângerile de egalitate sunt liniare, iar cele din constrângerile de inegalitate sunt convexe. Observăm că constrângerea $h(x) = 0$ este echivalentă cu egalitatea $x_1 + 2x_2 = 0$, a cărei funcție este liniară. Pentru $g_1(x) \leq 0$, observăm că este echivalentă cu $x^T x - 1 \leq 0$. Funcția $x^T x - 1$ este o funcție pătratică, diferențiabilă de două ori, cu Hessiana $2I_2 \succ 0$, deci satisface condițiile de convexitate de ordin II și este implicit convexă. Constrângerea $g_2(x) \leq 0$ este echivalentă cu:

$$-1 \leq (c^T x - d) \leq 1 \Rightarrow \begin{cases} c^T x - d \leq 1 \\ -c^T x + d \leq 1 \end{cases} \Rightarrow \begin{bmatrix} c^T \\ -c^T \end{bmatrix} x + \begin{bmatrix} -d \\ d \end{bmatrix} \leq \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

deci aceasta se reduce la o constrângere de inegalitate unde funcția este liniară și implicit convexă.

Problema 8. Să se determine problema convexă de programare semidefinită ce aproximează următoarea problemă neconvexă:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} & x^T A^T A x \\ \text{s.l.: } & \|x\|_2 \leq 1, \end{aligned}$$

unde $A \in \mathbb{R}^{m \times n}$ și $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$.

Rezolvare. Reamintim că pentru orice $Q \in \mathbb{R}^{n \times n}$ și $x \in \mathbb{R}^n$, funcția $\text{Tr}(Q)$ satisface relația: $\text{Tr}(x^T Q x) = \text{Tr}(Q x x^T)$. Pe baza acestei relații, problema precedentă se scrie sub următoarea formă echivalentă:

$$\begin{aligned} \max_{X \in \mathbb{R}^{n \times n}} \quad & \text{Tr}(A^T A X) \\ \text{s.l.:} \quad & \text{rang}(X) = 1, \text{Tr}(X) = 1. \end{aligned}$$

Se obține relaxarea convexă prin renunțarea la constrângerea de egalitate neliniară $\text{rang}(X) = 1$. În concluzie, avem următoarea aproximare convexă a problemei de optimizare originală:

$$\begin{aligned} \max_{X \in \mathbb{R}^{n \times n}} \quad & \text{Tr}(A^T A X) \\ \text{s.l.:} \quad & \text{Tr}(X) = 1. \end{aligned}$$

2.5 Probleme propuse

Problema 1. Să se determine care dintre următoarele funcții sunt convexe, concave sau niciuna dintre cele două variante. Să se argumenteze rezultatele obținute.

- (i) $f(x_1, x_2) = 2x_1^2 - 4x_1x_2 - 8x_1 + 3x_2$,
- (ii) $f(x_1, x_2) = x_1 e^{-(x_1 + 3x_2)}$,
- (iii) $f(x_1, x_2) = -x_1^2 - 3x_2^2 + 4x_1x_2 + 10x_1 - 10x_2$,
- (iv) $f(x_1, x_2, x_3) = 2x_1x_2 + 2x_1^2 + x_2^2 + 2x_3^2 - 5x_1x_3$,
- (v) $f(x_1, x_2, x_3) = -2x_1^2 - 3x_2^2 - 2x_3^2 + 8x_1x_2 + 3x_1x_3 + 4x_2x_3$.

Problema 2. Să se determine submulțimea din $\{x \in \mathbb{R} : x > 0\}$ pe care funcția $f(x) = e^{ax^b}$ este convexă. Parametrii a, b satisfac $a > 0, b \geq 1$.

Problema 3. Să se determine în domeniul axei reale în care funcția $f(x) = x^2(x^2 - 1)$ este convexă.

Problema 4. Fie funcțiile convexe $f_1, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$. Să se demonstreze că următoarele compuneri ale acestora sunt convexe:

- (i) $g(x) = \sum_{i=1}^m \alpha_i f_i(x)$, $\alpha_i > 0$,
- (ii) $h(x) = \max\{f_1(x), \dots, f_m(x)\}$.

Problema 5. Fie mulțimea $K = \{x \in \mathbb{R}^n : x \geq 0\}$. Să se demonstreze că mulțimea K este un con și să se determine conul dual corespunzător.

Problema 6. Să se demonstreze că funcția $f(x) = \sum_{i=1}^r \alpha_i x_{[i]}$ este convexă în x , unde $\alpha_1 \geq \dots \geq \alpha_r \geq 0$, iar $x_{[n]}$ reprezintă a n -a cea mai mare componentă din vectorul x .

Problema 7. Determinați funcțiile conjugate corespunzătoare funcțiilor:

- (i) $f(x) = \max_{1 \leq i \leq n} x_i$ cu domeniul \mathbb{R}^n ;
- (ii) $f(x) = x^p$ cu domeniul \mathbb{R}_{++} , unde $p > 1$. Comentați cazul în care $p < 0$.
- (iii) $f(x) = \left(-\prod_{i=1}^n x_i\right)^{1/n}$ cu domeniul \mathbb{R}_{++}^n ;
- (iv) $f(x, t) = -\log(t^2 - x^T x)$ cu domeniul $\{(x, t) \in \mathbb{R}^n \times \mathbb{R} : \|x\|_2 \leq t\}$.

Problema 8. Să se demonstreze că funcția:

$$f(x) = \frac{1}{x_1 - \frac{1}{x_2 - \frac{1}{x_3 - \frac{1}{x_4}}}},$$

definită pe domeniul în care toți numitorii sunt pozitivi, este convexă și strict descrescătoare. (Cazul când $n = 4$ nu prezintă nicio particularitate, caracteristicile funcției se mențin și pentru cazul general n oarecare.)

Problema 9. Presupunem că funcția f este convexă, iar $\lambda_1 > 0$, $\lambda_i \leq 0$ pentru $i = 2, \dots, n$ și $\sum_{i=1}^n \lambda_i = 1$. Fie punctele $x_1, \dots, x_n \in \text{dom} f$. Să se demonstreze că are loc inegalitatea:

$$f(\lambda_1 x_1 + \dots + \lambda_n x_n) \geq \lambda_1 f(x_1) + \dots + \lambda_n f(x_n).$$

Problema 10. Să se arate că o funcție $f : \mathbb{R} \rightarrow \mathbb{R}$ este convexă dacă și numai dacă domeniul $\text{dom} f$ este convex și

$$\det \begin{bmatrix} 1 & 1 & 1 \\ x & y & z \\ f(x) & f(y) & f(z) \end{bmatrix} \geq 0,$$

pentru orice $x, y, z \in \text{dom} f$ și $x < y < z$.

Problema 11. Să se arate că maximul unei funcții convexe peste poliedrul $\mathcal{P} = \text{conv}\{v_1, \dots, v_k\}$ este atins într-unul dintre vârfurile poliedrului, i.e.,

$$\sup_{x \in \mathcal{P}} f(x) = \max_{i=1, \dots, k} f(v_i).$$

Indiciu: Se presupune că afirmația este falsă și se utilizează inegalitatea lui Jensen.

Problema 12. Fie o funcție convexă f și o funcție g definită după cum urmează:

$$g(x) = \min_{\alpha > 0} \frac{f(\alpha x)}{\alpha}.$$

- (i) Să se demonstreze că funcția g este omogenă, i.e. $g(tx) = tg(x)$ pentru orice $t \geq 0$.
- (ii) Să se demonstreze că dacă o funcție h este omogenă și $h(x) \leq f(x)$ pentru orice x , atunci avem $h(x) \leq g(x)$ pentru orice x .
- (iii) Să se demonstreze că funcția g definită anterior este convexă.

Problema 13. Fie funcția omogenă $f : \mathbb{R}^n \rightarrow \mathbb{R}$, i.e. $f(tx) = tf(x)$ pentru orice $t \geq 0$ și $x \in \mathbb{R}^n$. O funcție omogenă se numește subaditivă dacă satisface, în plus, următoarea relație:

$$f(x) + f(y) \geq f(x + y).$$

Să se demonstreze că, pentru funcțiile omogene, subaditivitatea este echivalentă cu convexitatea.

Problema 14. Fie o mulțime S nevidă, mărginită și convexă în \mathbb{R}^n și o funcție f definită de:

$$f(x) = \max_{y \in S} y^T x.$$

Funcția f se numește *funcția suport* a mulțimii S .

- (i) Să se arate că funcția f este omogenă și convexă.
- (i) Să se determine explicit funcția suport pentru mulțimile S definite de

$$S = \{x \in \mathbb{R}^n : \|Ax\|_p \leq 1\} \quad p = 1, 2, \infty,$$

unde matricea A este inversabilă.

Problema 15. Fie funcția convexă $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Definim proprietatea de convexitate tare, enumerând condițiile de ordin 0, I și II (ce depind de gradul de diferențiabilitate al funcției), într-un mod similar cu cele corespunzătoare cazului convex. Pentru $\mu > 0$, funcția f se numește μ -tare convexă în raport cu norma- p dacă:

(Condiții de ordinul 0) funcția f satisface următoarea inegalitate pentru orice $x, y \in \mathbb{R}^n$:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) - \frac{\mu\alpha(1 - \alpha)}{2} \|x - y\|_p^2.$$

(Condiții de ordinul I) funcția f este diferențiabilă și satisface următoarea inegalitate pentru orice $x, y \in \mathbb{R}^n$:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_p^2.$$

(Condiții de ordinul II) funcția f este diferențiabilă de două ori și satisface următoarea inegalitate pentru orice $x \in \mathbb{R}^n$:

$$x^T \nabla^2 f(x) x \geq \mu \|x\|_p^2,$$

$$\text{unde } \|x\|_p = \left(\sum_{i=1}^n x_i^p \right)^{\frac{1}{p}}, \quad 1 \leq p \leq \infty.$$

Să se demonstreze că:

- (i) Pentru norma 2, condițiile de ordin I implică condițiile de ordin 0, i.e. dacă funcția f satisface condițiile de ordin I atunci ea satisface și condițiile de ordin 0.
- (ii) Pentru norma 2, orice funcție diferențiabilă o dată și μ -tare convexă satisface relația:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|_2^2.$$

- (iii) Funcția $g(x) = \frac{1}{2}\|x\|_2^2$ este 1-tare convexă în raport cu norma $\|\cdot\|_2$.
- (iv) Funcția $g(x) = \frac{1}{2}\|x\|_p^2$ este $(p-1)$ -tare convexă în raport cu norma $\|\cdot\|_p$, pentru $p > 1$.
- (v) Funcția $g(x) = \log n - \sum_{i=1}^n x_i \log x_i$ este 1-tare convexă în raport cu norma $\|\cdot\|_1$ pe domeniul $\{x \in \mathbb{R}_+^n : \|x\|_1 \leq 1\}$.

Problema 16. Fie funcția f definită de:

$$f(y, t) = \max_{x \in \mathbb{R}^n} \langle y, x \rangle - \frac{t}{2} \|x\|^2.$$

Determinați domeniul funcției f și arătați că expresia acesteia se rescrie în următoarea formă:

$$f(y, t) = \begin{cases} 0, & \text{dacă } y = 0, t = 0 \\ \frac{\|y\|^2}{2t}, & \text{dacă } t > 0. \end{cases}$$

Problema 17. Să se demonstreze că pentru o matrice simetrică și pozitiv definită $Q \in \mathbb{R}^{n \times n}$ și doi vectori $u, v \in \mathbb{R}^n$ are loc următoarea inegalitate:

$$|u^T v| \leq u^T Q u v^T Q^{-1} v.$$

Problema 18. Fie matricele E, H și F de dimensiuni compatibile și $F^T F \preceq I$. Să demonstreze că pentru orice $\alpha > 0$, avem

$$EFH + H^T F^T E^T \preceq \alpha E E^T + \frac{1}{\alpha} H^T H.$$

Indiciu: Se folosește inegalitatea $(\alpha E^T - FH)^T (\alpha E^T - FH) \succeq 0$.

Problema 19. Fie matricea simetrică M de forma:

$$M = \begin{bmatrix} A & B \\ B^T & C \end{bmatrix},$$

în care matricea C este inversabilă. Se numește *complementul Schur* al lui M , matricea $S = A - BC^{-1}B^T$. Un rezultat des folosit în teoria matriceală precizează că următoarele relații sunt echivalente:

- (i) $M \succeq 0$ (M este pozitiv semidefinită);

$$(ii) \ A \succeq 0, (I - AA^\dagger)B = 0, C - B^T A^\dagger B \succeq 0;$$

$$(iii) \ C \succeq 0, (I - CC^\dagger)B = 0, A - B^T C^\dagger B \succeq 0,$$

unde cu A^\dagger am notat pseudo-inversa matricei A . Mai mult, dacă $M \succ 0$ obținem un caz particular al echivalențelor:

$$(i)' \ M \succ 0 \ (M \text{ este pozitiv definită});$$

$$(ii)' \ A \succ 0, C - B^T A^{-1} B \succeq 0;$$

$$(iii)' \ C \succ 0, A - B^T C^{-1} B \succeq 0.$$

Evidențiem, mai departe, un exemplu de aplicație al acestui rezultat. Fie funcția $f : \mathbb{R}^n \times \mathcal{S}_{++}^n \rightarrow \mathbb{R}$ definită de:

$$f(x, Y) = x^T Y^{-1} x.$$

Să se demonstreze că f este convexă folosind proprietățile complementului Schur.