

Capitolul 5

Probleme de optimizare constrânsă

5.1 Preliminarii

Acest capitol delimitează începutul unei importante părți din teoria optimizării, și anume analiza problemelor de optimizare cu restricții. O problemă de optimizare constrânsă (cu restricții) în formă generală este dată prin următoarea expresie:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.l.:} \quad & g(x) \leq 0, \quad h(x) = 0, \end{aligned} \tag{5.1}$$

unde funcția obiectiv $f : \mathbb{R}^n \rightarrow \mathbb{R}$ și funcțiile vectoriale ce definesc constrângerile $g : \mathbb{R}^n \rightarrow \mathbb{R}^m, h : \mathbb{R}^n \rightarrow \mathbb{R}^p$, se presupune a fi de două ori diferențiabile.

Introducem, mai departe, o serie de noțiuni caracteristice problemelor de optimizare constrânse. *Lagrangianul* corespunzător problemei (5.1) este:

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \lambda^T g(x) + \mu^T h(x),$$

unde $\lambda \in \mathbb{R}^m$, $\mu \in \mathbb{R}^p$ reprezintă *multiplicatorii Lagrange* asociați constrângerilor de inegalitate, respectiv de egalitate. Condițiile necesare de ordin I pentru probleme constrânse de tip (5.1) se formulează astfel: dacă x^* este un punct de minim local al problemei (5.1), atunci există

$\lambda^* \in \mathbb{R}^m$ și $\mu^* \in \mathbb{R}^p$ astfel încât:

$$\begin{aligned} \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) + \sum_{i=1}^p \mu_i^* \nabla h_i(x^*) &= 0 \\ g(x^*) &\leq 0, h(x^*) = 0 \\ \lambda_i^* g_i(x^*) &= 0 \\ \lambda^* &\geq 0. \end{aligned}$$

Aceste relații formează *sistemul KKT* sau *condițiile de optimalitate Karush-Kuhn-Tucker*. În cazul nedegenerat, condițiile suficiente de optimalitate se enunță după cum urmează: dacă x^* satisface sistemul KKT iar Hessiana Lagrangianului dată de expresia:

$$\nabla_x^2 L(x^*, \lambda, \mu) = \nabla^2 f(x^*) + \sum_{i=1}^m \lambda_i \nabla^2 g_i(x^*) + \sum_{i=1}^p \mu_i \nabla^2 h_i(x^*)$$

este pozitiv definită pe subspațiul definit de:

$$M = \{d : \nabla h(x^*)d = 0, \nabla g_j(x^*)^T d = 0 \forall j \in \mathcal{A}(x^*)\} \quad (5.2)$$

unde $\mathcal{A}(x^*)$ este mulțimea constrângerilor active, atunci x^* este un punct de minim strict local.

5.2 Probleme rezolvate de laborator

În acest subcapitol vom utiliza mediul de programare Matlab pentru rezolvarea unui număr de exemple de probleme de optimizare constrânsă.

5.2.1 Formularea unei probleme de optimizare în formă standard

Exemplul 19. Un avion cargo are trei compartimente pentru transport mărfuri, pe care le notăm C_1 , C_2 și C_3 . Presupunem că toate cele trei compartimente sunt limitate din punct de vedere al greutateii și volumului admis așa cum se specifică în următorul tabel:

Compartiment	Limită greutate $[t]$	Limită volum $[m^3]$
C_1	10	6.8
C_2	16	8.6
C_3	8	5.3

Pentru a menține echilibrul avionului, încărcătura fiecărui compartiment trebuie să respecte un raport prestabilit cu limita de greutate corespunzătoare. Mărfurile transportate sunt descrise, în plus, și de profitul adus transportatorului. În cele ce urmează, precizăm pentru fiecare tip de marfă, notat de la M_1 la M_4 , datele corespunzătoare:

Tip marfă	Total disponibil [t]	Volum [m^3/t]	Profit [\$/t]
M_1	18	0.48	3100
M_2	15	0.65	3800
M_3	23	0.58	3500
M_4	12	0.39	2850

Ținând cont că avionul ne permite să stocăm mai multe tipuri de marfă într-un singur compartiment, se dorește determinarea cantităților corespunzătoare fiecărui tip de marfă astfel încât profitul pentru zbor să fie maxim.

- (i) Să se formuleze această problemă ca una de programare liniară.
- (ii) Să se rezolve problema liniară rezultată la punctul (i) cu ajutorul mediului Matlab utilizând funcția `linprog` și limbajul CVX.

Rezolvare. Evident, vectorul variabilelor de decizie pentru această problemă este dat de cantitățile de marfă ce trebuie alocate diferitelor compartimente. Din moment ce putem stoca mai multe tipuri de marfă într-un singur compartiment, avem posibilitatea de a stoca între 1 și 4 tipuri de marfă în fiecare compartiment. Astfel, avem următoarea variabilă de decizie:

$$x = [x_{11} \ x_{12} \ x_{13} \ x_{14} \ \dots \ x_{34} \ x_{44}]^T = \{x_{ij}\}_{1 \leq i \leq 3, 1 \leq j \leq 4},$$

unde $x \in \mathbb{R}^{12}$, indicele $i = 1, \dots, 3$ reprezintă numărul compartimentului, iar $j = 1, \dots, 4$ reprezintă tipul de marfă. Funcția obiectiv este liniară $f(x) = c^T x$ definită:

$$c = [3100 \ 3800 \ 3500 \ 2850 \ 3100 \ 3800 \ 3500 \ 2850 \ \dots]^T.$$

Pe de altă parte, formularea constrângerilor în formă standard presupune:

- constrângerea cantității disponibile per tip de marfă (nu putem livra mai mult decât este disponibil). Constrângerile în acest caz au forma: $x_{11} + x_{21} + x_{31} \leq 18$ pentru primul tip de marfă, $x_{12} + x_{22} + x_{32} \leq 15$ pentru al doilea tip ș.a.m.d;
- limitarea masei totale dintr-un compartiment la o cantitate maximă

admisă, i.e. $x_{11} + x_{12} + x_{13} + x_{14} \leq 10$, $x_{21} + x_{22} + x_{23} + x_{24} \leq 16$ etc;
 - volumul încărcăturilor este limitat la o anumită valoare în fiecare compartiment, i.e. $0.48x_{11} + 0.65x_{12} + 0.58x_{13} + 0.39x_{14} \leq 6.8$, $0.48x_{21} + 0.65x_{22} + 0.58x_{23} + 0.39x_{24} \leq 8.6$ etc;
 - prin definiția de pozitivitate a masei restricționăm cantitățile din fiecare marfă la valori nenegative: $x \geq 0$;
 - secțiunea din enunț: ”încărcăturile din compartimente trebuie să aibă același raport cu limitele lor de greutate” furnizează o serie de constrângeri de egalitate:

$$\begin{aligned}\frac{1}{10}(x_{11} + x_{12} + x_{13} + x_{14}) &= \frac{1}{16}(x_{21} + x_{22} + x_{23} + x_{24}) \\ \frac{1}{16}(x_{21} + x_{22} + x_{23} + x_{24}) &= \frac{1}{8}(x_{31} + x_{32} + x_{33} + x_{34}).\end{aligned}$$

În final, formularea de programare liniară este definită astfel:

$$\begin{aligned}\max_{x \in \mathbb{R}^{12}} c^T x \\ \text{s.l.: } Ax = b, \quad Cx \leq d,\end{aligned}$$

unde parametrii $A \in \mathbb{R}^{2 \times 12}$ și $b \in \mathbb{R}^2$ cuprind constrângerile de egalitate, iar cele de inegalitate sunt cuprinse în $Cx \leq d$ unde $C \in \mathbb{R}^{22 \times 12}$ și $d \in \mathbb{R}^{22}$.

(ii) Pentru simplitate, furnizăm doar codul în limbaj CVX pentru rezolvarea acestei probleme, deoarece sintaxa rezolvării cu funcția Matlab `linprog` este evidentă din apelarea comenzii `helplinprog` :

```
cvx_begin
variable x(12,1)
maximize ((c')*x)
subject to
A*x=b
C*x<=d
x>=0
cvx_end
```

5.2.2 Calcularea proiecției ortogonale a unui punct pe o mulțime convexă

Exemplul 20. Pentru fiecare din următoarele mulțimi convexe, să se calculeze proiecția ortogonală a punctului asociat utilizând CVX:

$$(i) \mathcal{B} = \{x \in \mathbb{R}^2 : \|x\| \leq 2\}, x_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix};$$

$$(ii) \mathcal{E} = \{x \in \mathbb{R}^2 : (x - c)^T P^{-1}(x - c) \leq 1\}, \text{ unde } P = \begin{bmatrix} 25 & 0 \\ 0 & 16 \end{bmatrix}, c = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, x_0 = \begin{bmatrix} -4 \\ -4 \end{bmatrix};$$

$$(iii) \mathcal{T} = \{x \in \mathbb{R}^3 : Ax \leq b\}, \text{ unde } A = \begin{bmatrix} -I_3 \\ \mathbf{1}_3^T \end{bmatrix}, b = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}, x_0 = \begin{bmatrix} 1.6 \\ 1.6 \\ 1.5 \end{bmatrix}.$$

Să se figureze grafic mulțimile, punctele asociate și proiecțiile ortogonale ale acestor puncte.

Rezolvare. În general, calculul proiecției ortogonale unui punct a_0 pe o mulțime X se realizează prin rezolvarea următoarei probleme de optimizare:

$$[a_0]_{(I_n, X)} = \arg \min_{x \in X} \|x - a_0\|^2. \quad (5.3)$$

(i) Secvența de cod CVX ce calculează proiecția $[x_0]_{(I_n, \mathcal{B})}$ unui punct x_0 pe mulțimea $\mathcal{B} \subset \mathbb{R}^2$ (vezi Fig. 5.1) este dată în cele ce urmează:

```
x0=[3;1];
cvx_begin
    variable xB(2);
    minimize (xB'*xB-2*xB'*x0+x0'*x0)
    subject to
        norm(xB)<=2;
cvx_end
```

Observând că mulțimea \mathcal{B} este de tip bilă cu rază 2 și centrul în origine, reprezentarea grafică este realizată prin:

```
%Mai intai gasim mai multe puncte din bila:
[x1,x2]=meshgrid(-2:0.1:2,-2:0.1:2);
z=sqrt(x1.^2+x2.^2);
d=(z<=2); ball1=[]; ball2=[];
for i=1:size(d,1)
    for j=1:size(d,2);
        if(d(i,j)==1)
```

```

        ball1=[ball1; x1(i,j)];
        ball2=[ball2; x2(i,j)];
    end
end
end

```

Mai departe, trasăm grafic toate elementele obținute:

```

figure(1)
hold on
axis([-4 4 -4 4]); scatter(ball1,ball2,'+');
plot(x0(1),x0(2),'ro','LineWidth',2);
plot(xB(1),xB(2),'r+','LineWidth',2);
legend('Bila B','x_0','x_B');hold off;

```




Figura 5.1: Proiecția unui punct exterior pe mulțime tip bilă.

(ii) Observăm ca mulțimea $\mathcal{E} \subset \mathbb{R}^2$ este un elipsoid definit de matricea P și centrat în punctul $(1, 1)$. Codul CVX pentru determinarea proiecției punctului x_0 pe mulțimea \mathcal{E} (vezi Fig. 5.2), este redat de următoarea secvență:

```

Pinv=inv([25 0; 0 16]);
x0=[-4;-4]; xc=[1;1];
cvx_begin
    variable xE(2);
    minimize(xE'*xE-2*xE'*x0+x0'*x0)
    subject to
        (xE-xc)'*Pinv*(xE-xc)<=1;
cvx_end

```

Trasarea grafică a mulțimii \mathcal{E} este realizată de secvența de cod:

```

[x1,x2]=meshgrid(-6:0.1:6,-6:0.1:6);
y=Pinv*xc; const=xc'*Pinv*xc;
z=x1.^2*Pinv(1,1)+x2.^2*Pinv(2,2)+2.*x1.*x2*Pinv(1,2)-...
2*(x1*y(1)+x2*y(2))+const;
d=(z<=1); ellipse1=[]; ellipse2=[];
for i=1:size(d,1)
    for j=1:size(d,2);
        if(d(i,j)==1)
            ellipse1=[ellipse1; x1(i,j)];
            ellipse2=[ellipse2; x2(i,j)];
        end
    end
end
figure(1)
hold on
axis([-7 7 -7 7]); scatter(ellipse1,ellipse2,'+');
plot(x0(1),x0(2),'ro','LineWidth',2);
plot(xE(1),xE(2),'r+','LineWidth',2);
legend('Elipsoidul E','x_0','x_E'); hold off;

```




Figura 5.2: Proiecția unui punct exterior pe mulțime tip elipsoid.

(iii) Calcularea proiecției unui punct x_0 pe mulțimea politopică \mathcal{T} (vezi Fig. 5.3) utilizând CVX se realizează în mod asemănător:

```

A=[-eye(3); ones(1,3)]; b=[zeros(3,1);1]; x0=[1;1;1];
cvx_begin
    variable xT(3,1);
    minimize (xT'*xT-2*xT'*x0+x0'*x0)
    subject to
        A*xT<=b;

```

cvx_end




Figura 5.3: Proiecția unui punct exterior pe mulțime tip politop.

Pentru a facilita reprezentarea grafică, observăm că mulțimea \mathcal{T} poate fi reprezentată ca acoperirea convexă a vârfurilor (vertex) sale. Astfel, obținându-se proiecția x_T a punctului x_0 pe mulțimea \mathcal{T} , reprezentarea grafică se realizează prin următoarea secvență de cod:

```
x=[1; 0; 0; 0]; y=[0 ; 1; 0 ; 0]; z=[0 ; 0; 1; 0];
figure(1)
hold on
tetramesh(tessellation,[x(:) y(:) z(:)]);
x0hp = plot3(x0(1),x0(2),x0(3), 'ro');
set(x0hp, 'markersize', 10);
xThp = plot3(xT(1),xT(2),xT(3), 'r+');
plot3(points(1,:),points(2,:),points(3,:), 'r--');
set(xThp, 'markersize', 10); cameramenu; grid;
hold off
```


5.2.3 Metoda Gauss-Newton

Exemplul 21. Considerăm următoarea problemă de optimizare constrânsă:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} & - \sum_{i=1}^n x_i \ln(x_i) \\ \text{s.l.: } & \sum_{i=1}^n x_i = 1, \quad \sum_{i=1}^n x_i c_i = m, \quad i = 1, 2, \dots, n, \end{aligned}$$

unde c_i și m sunt valori cunoscute.

Sistemul KKT al acestei probleme este definit de un sistem neliniar de ecuații $F(y) = 0$, unde vectorul y este compus din variabila primală x și multiplicatorii Lagrange μ asociați constrângerilor de egalitate, i.e.

$$y = \begin{bmatrix} x \\ \mu \end{bmatrix}$$

Rezolvarea sistemului KKT poate fi abordată prin două metode:

(i) *metoda Gauss-Newton*;

(ii) *metoda Newton clasică*.

Să se rezolve problema anterioară în Matlab prin aplicarea celor două metode enumerate.

Rezolvare. Metoda *Gauss-Newton* este o metodă destinată rezolvării de probleme CMMP neliniare, i.e. de exemplu:

$$\min_{y \in \mathbb{R}^n} \frac{1}{2} \|F(y)\|^2, \quad (5.4)$$

a cărei soluție rezolvă sistemul de ecuații $F(y) = 0$ în sens CMMP.

Procedura urmată de metoda Gauss-Newton presupune ca într-un punct dat y_k la iterația k , $F(y)$ este liniarizat:

$$F(y) \approx F(y_k) + J(y_k)(y - y_k),$$

unde $J(y)$ este Jacobianul lui $F(y)$. La următoarea iterație, y_{k+1} , poate fi determinată ca o soluție a problemei liniare aproximative:

$$y_{k+1} = \arg \min_{y \in \mathbb{R}^n} \frac{1}{2} \|F(y_k) + J(y_k)(y - y_k)\|^2.$$

Pentru simplitatea expunerii, renotăm $J(y_k)$ cu J_k , iar în loc de $F(y_k)$ folosim F_k . Dacă presupunem că $J_k^T J_k$ este inversabilă, atunci rezultă iterația metodei Gauss-Newton definită de:

$$\begin{aligned} y_{k+1} &= \arg \min_{y \in \mathbb{R}^n} \frac{1}{2} \|F_k + J_k(y - y_k)\|^2 \\ &= y_k + \arg \min_{d \in \mathbb{R}^n} \frac{1}{2} \|F_k + J_k d\|^2 \\ &= y_k - (J_k^T J_k)^{-1} J_k^T F_k. \end{aligned}$$

Astfel, în cazul particular în care $x \in \mathbb{R}^3$, punctul inițial este dat de $x^0 = [\frac{1}{9} \ \frac{3}{7} \ \frac{3}{10}]^T$, $m = 6$ și $c = [3 \ 6 \ 9]^T$, scriem funcția Matlab auxiliară cu sintaxa `[F,J]=Fgauss(y,c,m)` ce returnează în F și J valoarea vectorului $F(y)$ și a Jacobianului $J(y)$. Utilizăm criteriul de oprire $\|F(y)\| < \epsilon$, unde ϵ este toleranță prestabilită. Astfel, codul Matlab corespunzător implementării metodei Gauss-Newton este:

```
function y=gauss_newt
x0=[1/9; 3/7; 3/10];
c=[3;6;9];mu1=0; mu2=0;
y=[x0;mu1;mu2]; eps=0.0001;m=6;
[F,J]=Fgauss(y,p,m);
while(norm(F)>eps)
    y=y-(J'*J)^(-1)*J'*F;
    [F,J]=Fgauss(y,p,m);
end
```

În Fig. 5.4 observăm descreșterea lui $\|F(y)\|$.




Figura 5.4: Evoluția $\|F(y)\|$ pentru metoda Gauss-Newton.

Implementarea metodei Newton clasice o lăsăm ca exercițiu cititorului.

5.2.4 Metoda gradientului proiectat

Exemplul 22. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} & (x_1 - x_2)^2 + 6(x_1 - x_2)^4 + 4x_1 + 8x_2 \\ \text{s.l.: } & 4x_1 + 3x_2 \leq 5, \quad 2x_1 + x_2 \leq 3, \\ & x_1 + x_2 = 3. \end{aligned}$$

Să se rezolve problema în Matlab cu metoda gradientului proiectat.

Rezolvare. Metoda *gradient proiectat* presupune proiecția ortogonală a unui punct auxiliar (definit de deplasarea în direcția antigradientului) pe mulțimea constrângerilor notată cu X , i.e.

$$x_{k+1} = [x_k - \alpha_k \nabla f(x_k)]_{(I_n, X)},$$

unde α_k poate fi ales de exemplu prin metoda backtracking. Definiția proiecției ortogonale a unui punct y pe o mulțime X , notată $[y]_{(I_n, X)}$ este dată de soluția problemei:

$$\begin{aligned} [y]_{(I_n, X)} &= \arg \min_x \frac{1}{2} \|x - y\|^2 \\ \text{s.l.: } & x \in X. \end{aligned} \tag{5.5}$$

În general, proiecția pe mulțimea descrisă de:

$$X = \{x \in \mathbb{R}^n : Ax \leq b, Cx = d\},$$

se realizează observând formularea echivalentă a problemei (5.5):

$$\begin{aligned} \min_x & \frac{1}{2} x^T I_n x - (x_k)^T x \\ \text{s.l.: } & Ax \leq b, \quad Cx = d, \end{aligned}$$

ce poate fi abordată, de exemplu, cu funcția `quadprog` din Matlab.

În cazul particular prezentat, mulțimea constrângerilor este definită de:

$$X = \{x \in \mathbb{R}^2 : 4x_1 + 3x_2 \leq 5, 2x_1 + x_2 \leq 3, x_1 + x_2 = 3\}$$

Creăm funcțiile auxiliare:

$$[f, g] = f_proj(x) \quad f = \text{phi_proj}(\alpha, x, d),$$

unde prima funcție returnează $f(x)$ și $\nabla f(x)$, iar cea de-a doua returnează $f(x + \alpha d)$. Pentru criteriul de oprire, vom folosi $\|x_k - \bar{x}_k\| < \epsilon$, unde \bar{x}_k este vectorul $x_k - \alpha_k \nabla f(x_k)$ proiectat pe mulțimea constrângerilor. Astfel, codul Matlab pentru implementarea metodei gradientului proiectat este:

```
function x=projected_gradient(x0,eps)
x=x0;
%Multimea constrangerilor este poliedru
%definit de matricele si vectorii
A=[4 3; 2 1]; b=[5;-3];
C=[1 1]; d=3.5; xbar=x0+1; alpha2=0.5;
while (norm(xbar-x)>=eps)
    [f,g]=f_proj(x);
    alpha=fminsearch(@(alpha) phi_proj(alpha,x,-g),1);
    grad_step=x-alpha*g;
    xbar=quadprog(2*eye(2),-2*grad_step,A,b,C,d);
    x=x+alpha2*(xbar-x);
end
```

În Fig. 5.5 observăm punctele obținute de metoda gradientului proiectat, pornind din $x_0 = [-5 \ 2]$.




Figura 5.5: Puncte obținute de metoda gradientului proiectat.

5.3 Probleme rezolvate de seminar

5.3.1 Problema duală, condiții și puncte Karush-Kuhn- Tucker

Problema 1. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & \|Ax\|_{\infty} \\ \text{s.l: } \quad & \|x\|_1 \leq 1, \quad e^{x_1+x_2} = 1, \quad (a^T x - b)^2 \leq 1, \end{aligned}$$

unde $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, $a = [3 \ 4]^T$ și $b = 1$. Să se scrie această problemă de optimizare în formă LP explicită.

Rezolvare. Dacă considerăm matricea $A = \begin{bmatrix} a_1^T \\ a_2^T \end{bmatrix}$ și definiția normei infinit, atunci funcția obiectiv se poate scrie drept:

$$\|Ax\|_{\infty} = \left\| \begin{bmatrix} a_1^T \\ a_2^T \end{bmatrix} x \right\|_{\infty} = \max_x \{ |a_1^T x|, |a_2^T x| \}.$$

Introducem o variabilă artificială t pentru a muta funcția obiectiv în constrângeri, obținându-se astfel o problemă echivalentă cu cea originală:

$$\begin{aligned} \min_{x \in \mathbb{R}^2, t \in \mathbb{R}} \quad & t \\ \text{s.l: } \quad & |a_1^T x| \leq t, \quad |a_2^T x| \leq t, \\ & \|x\|_1 \leq 1, \quad e^{x_1+x_2} = 1, \quad (a^T x - b)^2 \leq 1. \end{aligned}$$

Din definiția modulului, observăm că putem scrie primele două constrângeri drept:

$$\begin{cases} -t \leq a_1^T x \leq t \\ -t \leq a_2^T x \leq t \end{cases} \Rightarrow \begin{cases} a_1^T x \leq t \\ a_2^T x \leq t \\ -a_1^T x \leq t \\ -a_2^T x \leq t \end{cases} \Rightarrow \begin{bmatrix} A \\ -A \end{bmatrix} x \leq t \mathbf{1}_4$$

unde $\mathbf{1}_4$ este vectorul de dimensiune 4 cu toate elementele egale cu 1. Dacă introducem două variabile adiționale s_1, s_2 , și ne reamintim

definiția normei 1, putem atunci rescrie constrângerea $\|x\|_1 \leq 1$ drept:

$$\|x\|_1 \leq 1 \Rightarrow |x_1| + |x_2| \leq 1 \Rightarrow \begin{cases} s_1 + s_2 \leq 1 \\ |x_1| \leq s_1 \\ |x_2| \leq s_2 \end{cases}$$

Observăm acum faptul că egalitatea $e^{x_1+x_2} = 1$ se reduce simplu la $x_1 + x_2 = 0$, iar constrângerea $(a^T x - b)^2 \leq 1$ se reduce la:

$$-1 \leq a^T x - b \leq 1 \Rightarrow \begin{cases} a^T x - b \leq 1 \\ -a^T x + b \leq 1 \end{cases}$$

Luând astfel o variabilă de decizie $z = [t \ x_1 \ x_2 \ s_1 \ s_2]^T$, problema noastră originală se poate rescrie ca un LP:

$$\begin{aligned} \min_{z \in \mathbb{R}^5} \quad & c^T z \\ \text{s.l.} \quad & A_z z = b_z \\ & C_z z \leq d_z \end{aligned}$$

unde $c = [1 \ 0 \ 0 \ 0 \ 0]^T$, $A_z = [0 \ 1 \ 1 \ 0 \ 0]$ și $b_z = 0$, iar

$$C_z = \begin{bmatrix} -1 & 2 & 1 & 0 & 0 \\ -1 & 1 & 2 & 0 & 0 \\ -1 & -2 & -1 & 0 & 0 \\ -1 & -1 & -2 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & -1 & 0 \\ 0 & -1 & 0 & -1 & 0 \\ 0 & 0 & 1 & 0 & -1 \\ 0 & 0 & -1 & 0 & -1 \\ 0 & 3 & 4 & 0 & 0 \\ 0 & -3 & -4 & 0 & 0 \end{bmatrix} \quad \text{și} \quad d_z = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 2 \\ 0 \end{bmatrix}.$$

Problema 2. Fie problema de optimizare următoare:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \|x\|_1 \\ \text{s.l.} \quad & Ax = b. \end{aligned}$$

- (i) Arătați că această problemă se poate reformula ca una de programare liniară.
(ii) Aduceți problema la forma de programare liniară (LP) *standard*.
(iii) Determinați problema duală corespunzătoare.

Rezolvare. (i) Utilizând definiția normei 1 obținem reformularea:

$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^n |x_i|$$

s.l.: $Ax = b$.

Mai departe, folosim procedura de reformulare a unei probleme de optimizare generale într-o problemă cu funcție obiectiv liniară, coborând în constrângeri componentele sumei:

$$\min_{x, t \in \mathbb{R}^n} \sum_{i=1}^n t_i$$

s.l.: $|x_i| \leq t_i, \quad i = 1, \dots, n,$
 $Ax = b$.

Din definiția modulului rezultă echivalența inegalității $|y| \leq t$ cu $-t \leq y \leq t$. Aplicând în problema noastră această transformare obținem o problemă de programare liniară:

$$\min_{x, t \in \mathbb{R}^n} \sum_{i=1}^n t_i$$

s.l.: $x_i \leq t_i, \quad i = 1, \dots, n,$
 $-x_i \leq t_i, \quad i = 1, \dots, n,$
 $Ax = b,$

- (ii) Forma standard a problemelor de programare liniară este definită de:

$$\min_{x \in \mathbb{R}^n} c^T x$$

s.l.: $Ax = b,$
 $x \geq 0.$

Pentru a aduce problema de la punctul (i) la forma standard, introducem un set de variabile "virtuale", rescriind fiecare variabilă de decizie din problema de optimizare inițială:

$$x_i = x_i^+ - x_i^-, \quad \text{unde } x_i^+ \geq 0, x_i^- \geq 0.$$

În plus, reformulăm inegalitățile în următorul mod:

$$\begin{aligned} t_i - x_i &= s_{2i-1}, \text{ unde } s_{2i-1} \geq 0, \\ t_i + x_i &= s_{2i}, \text{ unde } s_{2i} \geq 0, \end{aligned}$$

$i = 1, \dots, n$.

Cu ajutorul acestei reformulări obținem o problemă de programare liniară în formă standard:

$$\begin{aligned} \min_{x^+, x^-, t \in \mathbb{R}^n, s \in \mathbb{R}^{2n}} \quad & \sum_{i=1}^n t_i \\ \text{s.l.: } & t_i - x_i = s_{2i-1}, \\ & t_i + x_i = s_{2i}, \quad i = 1, \dots, n, \\ & A(x^+ - x^-) = b, \\ & s \geq 0, x^+ \geq 0, x^- \geq 0, t \geq 0. \end{aligned}$$

unde $x^+ = [x_1^+ \dots x_n^+]^T$, $x^- = [x_1^- \dots x_n^-]^T$.

Mai compact avem:

$$\begin{aligned} \min_{z \in \mathbb{R}^{5n}} \quad & c^T z \\ \text{s.l.: } & Dz = d \\ & z \geq 0, \end{aligned}$$

$$\text{unde } z = \begin{bmatrix} x^+ \\ x^- \\ t \\ s \end{bmatrix}, D = \begin{bmatrix} M \\ N \end{bmatrix}, M \in \mathbb{R}^{m \times 5n}, N \in \mathbb{R}^{2n \times 5n}.$$

(iii) Pentru a determina problema duală, calculăm Lagrangianul asociat problemei primale:

$$\begin{aligned} \mathcal{L}(x, t, \lambda, \mu^+, \mu^-) &= \sum_{i=1}^n t_i + \lambda^T (Ax - b) + \mu^{+T} (t - x) - \mu^{-T} (t + x) \\ &= (e + \mu^+ - \mu^-)^T t - \mu^{+T} x - \mu^{-T} x + \lambda^T (Ax - b) \\ &= (e + \mu^+ - \mu^-)^T t + (A^T \lambda - \mu^+ - \mu^-)^T x - \lambda^T b, \end{aligned}$$

unde vectorul e are componentele egale cu 1. Obținem funcția duală prin minimizarea Lagrangianului în raport cu variabilele primale:

$$q(\lambda, \mu^+, \mu^-) = \min_{x, t \in \mathbb{R}^n} (e + \mu^+ - \mu^-)^T t + (A^T \lambda - \mu^+ - \mu^-)^T x - \lambda^T b.$$

Observând că $q(\lambda, \mu^+, \mu^-)$ ia valori finite doar în cazul în care

$$\begin{aligned} e + \mu^+ - \mu^- &= 0 \\ A^T \lambda - \mu^+ - \mu^- &= 0, \end{aligned}$$

aceste relații au rolul de constrângeri în componența problemei duale. În concluzie, problema duală asociată problemei din enunț este dată de:

$$\begin{aligned} \max_{\lambda, \mu^+, \mu^-} \quad & -\lambda^T b \\ & e + \mu^+ - \mu^- = 0 \\ & A^T \lambda - \mu^+ - \mu^- = 0 \\ & \mu^+ \geq 0, \mu^- \geq 0. \end{aligned}$$

Remarca 3. Observați că problema din enunț reprezintă proiecția ortogonală a punctului 0 pe subspațiul $Ax = b$, în raport cu norma 1.

Problema 3. Fie problema de programare liniară:

$$\begin{aligned} \min_{x_1, x_2} \quad & 50x_1 + 80x_2 \\ \text{s.l.:} \quad & 3x_1 \geq 6, \quad 2x_1 + 4x_2 \geq 10, \\ & 2x_1 + 5x_2 \geq 8, \quad x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

Determinați problema duală corespunzătoare.

Rezolvare. Pentru o expunere simplă notăm funcția obiectiv și constrângerile problemei precedente după cum urmează:

$$\begin{aligned} \min_{x_1, x_2} \quad & c^T x \\ \text{s.l.:} \quad & Ax \leq b, \quad x \geq 0, \end{aligned}$$

unde $c = \begin{bmatrix} 50 \\ 80 \end{bmatrix}$, $A = \begin{bmatrix} -3 & 0 \\ -2 & -4 \\ -2 & -5 \end{bmatrix}$, $b = \begin{bmatrix} -6 \\ -10 \\ -8 \end{bmatrix}$. În continuare, observăm că Lagrangianul problemei este dat de relația:

$$\mathcal{L}(x, \lambda_1, \lambda_2) = c^T x + \lambda_1^T (Ax - b) - \lambda_2^T x,$$

unde $\lambda_1 \in \mathbb{R}^3$, $\lambda_1 = [\lambda_1^1 \quad \lambda_1^2 \quad \lambda_1^3]^T$, iar $\lambda_2 \in \mathbb{R}^2$.

Funcția duală $q(\lambda_1, \lambda_2) = \min_{x \in \mathbb{R}^2} (c + A^T \lambda_1 - \lambda_2)x - \lambda_1^T b$ ia valori finite atunci când $c + A^T \lambda_1 - \lambda_2 = 0$. De aceea, impunând această constrângere variabilelor duale, rezultă problema duală:

$$\begin{aligned} \max_{\lambda_1 \in \mathbb{R}^3, \lambda_2 \in \mathbb{R}^2} \quad & -\lambda_1^T b \\ \text{s.l.: } & c + A^T \lambda_1 - \lambda_2 = 0, \\ & \lambda_1 \geq 0, \lambda_2 \geq 0, \end{aligned}$$

sau echivalent,

$$\begin{aligned} \max_{\lambda_1 \in \mathbb{R}^3, \lambda_2 \in \mathbb{R}^2} \quad & -\lambda_1^T b \\ \text{s.l.: } & c + A^T \lambda_1 \geq 0, \\ & \lambda_2 \geq 0. \end{aligned}$$

Mai exact, substituind valorile parametrilor obținem:

$$\begin{aligned} \max_{\lambda_1 \in \mathbb{R}^3, \lambda_2 \in \mathbb{R}^2} \quad & 6\lambda_1^1 + 10\lambda_1^2 + 8\lambda_1^3 \\ \text{s.l.: } & 3\lambda_1^1 + 2\lambda_1^2 + 2\lambda_1^3 \leq 50, \\ & 4\lambda_1^2 + 5\lambda_1^3 \leq 80, \\ & \lambda_2 \geq 0. \end{aligned}$$

Problema 4. Numeroase probleme din statistică, învățare automată, recunoaștere de imagini/fețe, presupun clasificarea de obiecte sau imagini prin determinarea unui model matematic capabil să recunoască și să încadreze într-o clasă o instanță nouă de obiect/imagini. Una dintre cele mai renumite tehnici de recunoaștere/clasificare este SVM (*Support Vector Machine*), ce se formulează sub forma unei probleme pătratice de optimizare:

$$\begin{aligned} \min_{a \in \mathbb{R}^n, b \in \mathbb{R}} \quad & \frac{1}{2} \|a\|^2 \\ \text{s.l.: } & c_i (a^T y_i - b) \geq 1, \quad i = 1, \dots, m. \end{aligned}$$

Variabilele de decizie a, b reprezintă parametrii unui hiperplan de separare a claselor de obiecte/imagini, așa cum se observă în Fig. 5.6 (vezi [1]). Să se determine problema duală.




Figura 5.6: Hiperplan de separare a două clase de obiecte.

Rezolvare. Lagrangianul problemei este dat de relația:

$$\mathcal{L}(x, \lambda) = \frac{1}{2} \|a\|^2 - \sum_{i=1}^n \lambda_i [c_i(a^T y_i - b) - 1].$$

Forma explicită a funcției duale:

$$q(\lambda) = \min_{a \in \mathbb{R}^n, b \in \mathbb{R}} \frac{1}{2} \|a\|^2 - \sum_{i=1}^n \lambda_i [c_i(a^T y_i - b) - 1],$$

este definită de condițiile de optimalitate de ordin I:

$$a^* - \sum_{i=1}^n c_i \lambda_i y_i = 0, \quad \sum_{i=1}^n c_i \lambda_i = 0.$$

Ambele relații se obțin din derivarea Lagrangianului în raport cu a , respectiv cu b , anularea expresiei rezultate și egalarea cu 0. Deoarece a doua egalitate asigură că funcția duală ia valori finite, aceasta devine o constrângere necesară a problemei duale. De aceea, prin substituirea valorii optime a^* în expresia Lagrangianului avem:

$$\begin{aligned} q(\lambda) &= \frac{1}{2} \left\| \sum_{i=1}^n c_i \lambda_i y_i \right\|^2 - \sum_{i=1}^n \sum_{j=1}^n \lambda_i c_i c_j \lambda_j (y_i^T y_j) + \sum_{i=1}^n \lambda_i \\ &= \frac{1}{2} \left\| \sum_{i=1}^n c_i \lambda_i y_i \right\|^2 - \left\| \sum_{i=1}^n c_i \lambda_i y_i \right\|^2 + \sum_{i=1}^n \lambda_i \\ &= -\frac{1}{2} \left\| \sum_{i=1}^n c_i \lambda_i y_i \right\|^2 + \sum_{i=1}^n \lambda_i, \end{aligned}$$

putem obține problema duală asociată, care observăm că este concavă:

$$\begin{aligned} \max_{\lambda \in \mathbb{R}^m} \quad & -\frac{1}{2} \left\| \sum_{i=1}^n c_i \lambda_i y_i \right\|^2 + \sum_{i=1}^n \lambda_i \\ \text{s.l.:} \quad & \sum_{i=1}^n c_i \lambda_i = 0, \quad \lambda_i \geq 0, \forall i = 1, \dots, n. \end{aligned}$$

Utilizând notațiile $\lambda = [\lambda_1 \dots \lambda_m]^T$, $c = [c_1 \dots c_m]^T$, $e = [1 \dots 1]^T$ și observând forma pătratică a problemei duale obținem reformularea:

$$\begin{aligned} \max_{\lambda \in \mathbb{R}^m} \quad & -\frac{1}{2} \lambda^T Q \lambda - e^T \lambda \\ \text{s.l.:} \quad & c^T \lambda = 0, \quad \lambda \geq 0, \end{aligned}$$

unde matricea $Q \in \mathbb{R}^m$, $Q = Q^T$, are elementele $Q_{ij} = c_i c_j a_i^T a_j$.

Problema 5. Fie problema celor mai mici pătrate (CMMP), ce presupune calculul unei soluții corespunzătoare unui sistem liniar de ecuații subdeterminat. Se observă ușor că problema se reduce la determinarea unui vector de normă minimă ce satisface sistemul liniar studiat:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|x\|^2 \\ \text{s.l.:} \quad & Ax = b, \end{aligned}$$

unde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Să se calculeze problema duală a problemei de minimizare.

Rezolvare. Deoarece problema de minimizare prezintă doar constrângeri de tip egalitate, definim Lagrangianul:

$$\mathcal{L}(x, \mu) = \frac{1}{2} x^T x + \mu^T (Ax - b).$$

Astfel, funcția duală este dată de soluția problemei următoare:

$$q(\mu) = \min_{x \in \mathbb{R}^n} \frac{1}{2} x^T x + \mu^T (Ax - b).$$

Se obține ușor soluția $x^* = -A^T \mu$. Substituind în problema precedentă, obținem funcția duală pătratică concavă:

$$q(\mu) = -\frac{1}{2} \mu^T A A^T \mu - \mu^T b.$$

În concluzie, problema duală poate fi formulată ca o problemă pătratică convexă:

$$q^* = \max_{\mu \in \mathbb{R}^m} -\frac{1}{2}\mu^T AA^T \mu - \mu^T b.$$

Mai mult decât atât, din condițiile de optimalitate ale problemei duale avem: $\nabla q(\mu) = -AA^T \mu - b = 0$. În cazul în care $\text{rang}(A) = m$, obținem $\mu^* = -(AA^T)^{-1}b$ și $x^* = A^T(AA^T)^{-1}b$, cu remarcă importantă că x^* este soluția clasică CMMP.

Problema 6. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2}x^T x \\ \text{s.l.:} \quad & Ax \leq b, \end{aligned}$$

unde $A \in \mathbb{R}^{m \times n}$, iar $\text{rang}(A) = m$. Să se determine problema duală și punctul de optim.

Rezolvare. Pentru determinarea problemei duale calculăm Lagrangianul problemei primale:

$$\mathcal{L}(x, \lambda) = \frac{1}{2}x^T x + \lambda^T (Ax - b).$$

De asemenea, funcția duală este dată de:

$$q(\lambda) = \min_{x \in \mathbb{R}^n} \mathcal{L}(x, \lambda) = \min_{x \in \mathbb{R}^n} \frac{1}{2}x^T x + \lambda^T (Ax - b).$$

Deoarece funcția obiectiv a acestei probleme este convexă, condițiile de optimalitate de ordin I sunt suficiente pentru determinarea optimului $x^*(\lambda) = -A^T \lambda$, iar prin substituția în $q(\lambda)$ obținem:

$$\begin{aligned} q(\lambda) &= \frac{1}{2}\lambda^T AA^T \lambda + \lambda^T (A(-A^T \lambda) - b) \\ &= -\frac{1}{2}\lambda^T AA^T \lambda - \lambda^T b. \end{aligned}$$

În final, problema duală este definită de:

$$q^* = \max_{\lambda \geq 0} q(\lambda) \quad \left(:= -\frac{1}{2}\lambda^T AA^T \lambda - \lambda^T b \right). \quad (5.6)$$

Dacă matricea A are rangul maxim (implicit AA^T inversabilă și pozitiv definită), observăm că soluția problemei (5.6) este dată de:

$$\lambda^* = \arg \min_{\lambda \geq 0} \frac{1}{2} \|A^T \lambda + A^T (AA^T)^{-1} b\|_2^2 = \arg \min_{\lambda \geq 0} \frac{1}{2} \|A^T (\lambda + (AA^T)^{-1} b)\|_2^2.$$

În concluzie, observăm un compromis între problema primală și cea duală: în cazul problemei primale funcția obiectiv are o formă foarte simplă, iar constrângerile reprezintă dificultatea centrală; în cazul problemei duale, funcția obiectiv este relativ complicată, iar constrângerile au formă simplă.

Problema 7. Fie problema de optimizare constrânsă:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x - \sum_{i=1}^n x_i \ln x_i \\ \text{s.l.} \quad & \sum_{i=1}^n x_i = 1, \quad x \geq 0, \end{aligned}$$

unde $c \in \mathbb{R}^n$. (i) Să se determine dacă problema este convexă.
(ii) Să se determine un punct KKT pentru această problemă.

Rezolvare. (i) Pentru a determina convexitatea problemei, observăm în primul rând că toate constrângerile sunt liniare, deci mulțimea constrângerilor este convexă. În cazul funcției obiectiv însă, calculăm matricea Hessiană:

$$\nabla^2 f(x) = \begin{bmatrix} -\frac{1}{x_1} & 0 & \dots & 0 \\ 0 & -\frac{1}{x_2} & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & \dots & 0 & -\frac{1}{x_n} \end{bmatrix}$$

și observăm că este negativ semidefinită pe tot domeniul de definiție al funcției obiectiv $\text{dom} f = \mathbb{R}_+^n$. În concluzie, funcția obiectiv este concavă, rezultând o problemă de optimizare neconvexă.

(ii) Indicăm o procedură relativ inedită pentru determinarea unui punct KKT. Și anume, folosim structura problemei observând condițiile de optimalitate de ordin I:

$$c_i - \ln x_i - 1 = 0, \forall i = 1, \dots, n.$$

Aceste condiții furnizează punctul de optim neconstrâns definit de componentele $x_i^* = e^{c_i-1}$.

Dacă proiectăm punctul de optim neconstrâns pe hiperplanul:

$$H = \left\{ x \in \mathbb{R}^n : \sum_{i=1}^n x_i = 1 \right\}$$

obținem vectorul y^* definit de componentele:

$$y_i^* = \frac{e^{c_i-1}}{\sum_{j=1}^n e^{c_j-1}} \geq 0, \quad \sum_i y_i^* = 1.$$

În final, verificăm dacă y^* obținut satisface următorul sistem KKT:

$$\begin{cases} c_i - \ln y_i^* - 1 + \lambda_i^* + \mu^* = 0, \\ \sum_{i=1}^n y_i^* = 1, \quad y_i^* \geq 0, \\ \lambda_i^* \geq 0, \\ \lambda_i^* y_i^* = 0, \quad i = 1, \dots, n. \end{cases}$$

Observând că $y_i^* > 0$ atunci condițiile de complementaritate impun $\lambda_i^* = 0$ pentru orice $i = 1 \dots n$. De asemenea, condiția de optimalitate $c_i - (c_i - 1) + \ln \sum_{j=1}^n e^{c_j} - 1 + \mu = 0$ este satisfăcută dacă impunem $\mu = -\ln \sum_j e^{c_j}$. În aceste condiții, y^* satisface condițiile KKT, fiind un punct staționar pentru problema din enunț.

Problema 8. Fie problema de minimizare:

$$\begin{aligned} \min_{x_1, x_2 \in \mathbb{R}} \quad & x_2 \\ \text{s.l.:} \quad & 1 - x_1^2 - x_2^2 \geq 0. \end{aligned}$$

- (i) Determinați punctele KKT pentru această problemă.
- (ii) Găsiți punctele de minim strict locale.

Rezolvare. (i) Funcția Lagrange corespunzătoare funcției obiectiv are următoarea formă:

$$\mathcal{L}(x, \mu) = x_2 + \lambda(x_1^2 + x_2^2 - 1).$$

Derivând Lagrangianul în funcție de variabilele x_1 și x_2 rezultă următorul sistem KKT asociat problemei:

$$\begin{cases} 2\lambda x_1 = 0 \\ 1 + 2\lambda x_2 = 0 \\ x_1^2 + x_2^2 - 1 \leq 0 \\ \lambda \geq 0 \\ \lambda(x_1^2 + x_2^2 - 1) = 0. \end{cases}$$

Prima relație $\lambda x_1 = 0$ impune $x_1 = 0$ sau $\lambda = 0$. Constatăm ușor că pentru $\lambda = 0$, sistemul nu are soluție. De aceea, din $x_1 = 0$ avem $x_2 = -\frac{1}{2\lambda}$ și substituind în constrângerea de tip inegalitate obținem:

$$\frac{1}{4\lambda^2} - 1 \leq 0 \Rightarrow \lambda^2 \geq \frac{1}{4}.$$

Din moment ce $\lambda \geq 0$, avem $\lambda \geq \frac{1}{2}$. Iar din relația de complementaritate avem:

$$\frac{\lambda - 4\lambda^2}{4\lambda^2} = 0 \Rightarrow \lambda = \frac{1}{2}.$$

În concluzie, $x_2 = -1$, iar punctele KKT în acest caz sunt definite de: $x^* = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$ și $\lambda^* = \frac{1}{2}$.

(ii) Pentru a arăta că punctul KKT găsit este punct de minim, calculăm mai întâi planul tangent:

$$M = \{d: \nabla g_j(x^*)^T d = 0 \forall j \in \mathcal{A}(x^*)\}$$

unde $\mathcal{A}(x^*) = \{j: g_j(x^*) = 0\}$. Evident pentru $x^* = [0 \ -1]^T$, constrângerea noastră $g(x^*) = (x_1^*)^2 + (x_2^*)^2 - 1 = 0$, deci este activă, iar $\lambda^* = \frac{1}{2} \geq 0$. Gradientul funcției de constrângere este:

$$\nabla g(x) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix} \quad (5.7)$$

iar $\nabla g(x^*) = [0 \ -2]^T$. Astfel, planul tangent este:

$$M = \{d \in \mathbb{R}^2: d_2 = 0\}$$

Pentru ca x^* să fie punct de minim strict, atunci $\nabla_x^2 L(x^*, \lambda^*)$ trebuie să fie pozitiv definită pe M . Printr-un calcul simplu, observăm că:

$$\nabla_x^2 L(x^*, \lambda^*) = \begin{bmatrix} 2\lambda^* & 0 \\ 0 & 2\lambda^* \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Deci pentru $d \in M$ avem:

$$d^T \nabla_x^2 L(x^*, \lambda^*) d = d_1^2 > 0$$

și concluzionăm că $x^* = [0 \ -1]^T$ este punct de minim strict local.

Problema 9. Fie problema de optimizare constrânsă:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & \frac{1}{2}(x_1^2 + x_2^2) \\ \text{s.l.} \quad & (x_1 + x_2 - 1)^2 = 0 \end{aligned}$$

(i) Să se arate că problema este convexă.

(ii) Să se rezolve sistemul KKT asociat problemei. Verificați dacă punctul obținut este punct de minim global.

Rezolvare. (i) Funcția obiectiv se formulează matriceal $f(x) = \frac{1}{2}x^T I_2 x$. Observăm că Hessiana acesteia este pozitiv definită, deci funcția obiectiv este convexă. Pe de altă parte, constrângerea $(x_1 + x_2 - 1)^2 = 0$ este evident echivalentă cu egalitatea liniară $x_1 + x_2 - 1 = 0$. Deoarece singura constrângere este liniară, avem că mulțimea fezabilă este convexă.

(ii) Derivând Lagrangianul asociat problemei:

$$\mathcal{L}(x, \mu) = \frac{1}{2}(x_1^2 + x_2^2) + \mu(x_1 + x_2 - 1)$$

obținem sistemul KKT:

$$\begin{cases} x_1 + \mu = 0 \\ x_2 + \mu = 0 \\ x_1 + x_2 - 1 = 0 \end{cases}$$

din care rezultă $\mu^* = -\frac{1}{2}$ și $x_1^* = x_2^* = \frac{1}{2}$. Pentru a verifica dacă x^* este punct de minim strict local, atunci calculăm mai întâi planul tangent

$$M = \{d \in \mathbb{R}^2 : \nabla h(x^*)d = 0\} = \{d \in \mathbb{R}^2 : d_1 + d_2 = 0\}. \quad (5.8)$$

Remarcând că:

$$d^T \nabla^2 f(x^*) d = d_1^2 + d_2^2 > 0, \quad \forall d \in M,$$

concluzionăm că x^* este punct de minim global strict.

Problema 10. Fie următoarea problemă:

$$\begin{aligned} \min_{x \in \mathbb{R}^3} f(x) &:= \frac{1}{2}(x_1^2 + x_2^2 + x_3^2) \\ \text{s.l } g_1(x) &:= x_1 + x_2 + x_3 \leq 0 \\ g_2(x) &:= x_1 \leq 0. \end{aligned}$$

Să se găsească punctele KKT asociate.

Rezolvare. Observăm că orice punct fezabil pentru această problemă este un *punct regulat*, iar din condițiile ale sistemului KKT obținem:

<i>Optimalitate</i>	<i>Fezabilitate</i>	<i>Complementaritate</i>
$x_1^* + \lambda_1^* + \lambda_2^* = 0,$	$x_1^* + x_2^* + x_3^* \leq 0, \quad x_1^* \leq 0,$	$\lambda_1^*(x_1^* + x_2^* + x_3^*) = 0,$
$x_2^* + \lambda_1^* = 0,$	$\lambda_1^* \geq 0, \quad \lambda_2^* \geq 0,$	$\lambda_2^* x_1^* = 0.$
$x_3^* + \lambda_1^* = 0,$		

Din condițiile de optimalitate avem $x_1^* = -\lambda_1^* - \lambda_2^*, x_2^* = -\lambda_1^*, x_3^* = -\lambda_1^*$. Substituind aceste expresii în condițiile de complementaritate rezultă sistemul:

$$\begin{aligned} 3(\lambda_1^*)^2 + \lambda_1^* \lambda_2^* &= 0, \\ (\lambda_2^*)^2 + \lambda_1^* \lambda_2^* &= 0, \end{aligned}$$

ce elimină posibilitățile ca $\lambda_1^* = 0, \lambda_2^* > 0$ sau $\lambda_1^* > 0, \lambda_2^* = 0$. De aceea, rămâne să verificăm cazurile când $\lambda_1^* > 0, \lambda_2^* > 0$ sau $\lambda_1^* = 0, \lambda_2^* = 0$. Primul din cazurile rămase nu este posibil deoarece $x_1^* = -\lambda_1^* - \lambda_2^*$ și a doua condiție de complementaritate nu este satisfăcută. În concluzie, doar punctul nul satisface condițiile KKT.

Problema 11. Fie problema de optimizare constrânsă:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} x_1^2 - x_2^2 \\ x_1 + x_2 \geq 0. \end{aligned}$$

- (i) Să se determine punctele KKT;
- (ii) Aflați funcția duală și problema duală.

Rezolvare. (i) Lagrangianul acestei probleme este definit de:

$$\mathcal{L}(x, \lambda) = x_1^2 - x_2^2 - \lambda(x_1 + x_2),$$

deci sistemul KKT este dat de:

$$\begin{cases} \nabla_x \mathcal{L}(x^*, \lambda^*) = 0, \\ -x_1^* - x_2^* \leq 0, \\ \lambda^* \geq 0, \\ -\lambda^*(x_1^* + x_2^*) = 0. \end{cases}$$

Din prima ecuație a sistemului KKT rezultă:

$$x_1^* = \frac{\lambda^*}{2}, \quad x_2^* = -\frac{\lambda^*}{2}.$$

Înlocuind în ultima ecuație și remarcând că fezabilitatea primală este satisfăcută, deducem că λ^* poate lua o infinitate de valori.

(ii) Remarcăm o expresie neobișnuită a funcției duale:

$$q(\lambda) = \min_{x \in \mathbb{R}^2} L(x, \lambda) = \min_{x \in \mathbb{R}^2} x_1^2 - x_2^2 - \lambda(x_1 + x_2) = 0,$$

de aceea constatăm că problema duală nu este o problemă de optimizare propriu-zisă: $\max_{\lambda \geq 0} 0$.

5.4 Probleme propuse

Problema 1. Să se arate că $x^* = [1 \ 1/2 \ -1]^T$ este punctul minim global pentru următoarea problemă de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & \frac{1}{2} x^T P x + q^T x + r \\ \text{s.l.:} \quad & -1 \leq x_i \leq 1, \quad i = 1, 2, 3, \end{aligned}$$

unde

$$P = \begin{bmatrix} 13 & 12 & -2 \\ 12 & 17 & 6 \\ -2 & 6 & 12 \end{bmatrix}, \quad q = \begin{bmatrix} -22.0 \\ -14.5 \\ 13 \end{bmatrix}, \quad r = 1.$$

Problema 2. Să se determine condițiile necesare și suficiente în cea mai simplă formă pentru ca $x \in \mathbb{R}^n$ să reprezinte punctul de optim corespunzător unei funcții convexe diferențiabile f peste mulțimea de

tip simplex, i.e.: $\{x : \sum_{i=1}^n x_i = 1, x_i \geq 0, i = 1, \dots, n\}$.

Problema 3. Să se înlocuiască funcția obiectiv din problema 1 (Probleme rezolvate) cu $\|x\|_\infty$ și să se rezolve noua problemă.

Problema 4. Să se determine sistemul KKT pentru următoarea problemă de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 + x_2^2 \\ \text{s.l} \quad & (x_1 - 1)^2 + (x_2 - 1)^2 \leq 1, \\ & (x_1 - 1)^2 + (x_2 + 1)^2 \leq 1. \end{aligned}$$

Există multiplicatori Lagrange λ_1^* și λ_2^* care să demonstreze că punctul x^* este optim?

Problema 5. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & x_1^4 + x_2^4 + x_3^4 + (x_1 + 2x_2 - 4)^2 \\ \text{s.l} \quad & x_1 + x_2 + x_3 = 1, x \geq 0. \end{aligned}$$

Să se scrie primul pas al metodei gradient proiectat, pornind din punctul inițial $x_0 = [1 \ 0 \ 0]^T$ și alegând pasul $s_k = 1$.

Problema 6. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^4 + x_2^4 + (x_1 - 1)^2 + (x_2 - 4)^2 \\ \text{s.l} \quad & x_1 + x_2 = 16 \end{aligned}$$

Să se scrie aproximarea Taylor de ordin II pentru funcția obiectiv și să se scrie primul pas al metodei Newton proiectat pornind din punctul inițial $x_0 = [14 \ 2]^T$.

Problema 7. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 + 1 \\ \text{s.l} \quad & (x - 1)(x - 4) \leq 0 \end{aligned}$$

Să se determine mulțimea fezabilă, punctul de minim și valoarea minimă pentru această problemă. Să se traseze pe același grafic funcția obiectiv,

mulțimea fezabilă, punctul de minim și Lagrangianul $\mathcal{L}(x, \lambda)$ pentru două valori pozitive ale lui λ luate la alegere. Să se formuleze problema duală, să se demonstreze că este concavă și să se găsească punctul optim dual λ^* .

Problema 8. Considerăm problema celor mai mici pătrate cu constrângeri de egalitate:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} & \|Ax - b\|_2^2 \\ \text{s.l.: } & Cx = d \end{aligned}$$

unde $A \in \mathbb{R}^{m \times n}$, $\text{rang}(A) = n$, $C \in \mathbb{R}^{p \times n}$, cu $\text{rang}(C) = p$. Să se explicitizeze condițiile KKT ale acestei probleme și să se determine expresia soluției primale x^* și a celei duale μ^* .

Problema 9. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} & -3x_1^2 + x_2^2 + 2x_3^2 + 2(x_1 + x_2 + x_3) \\ \text{s.l.: } & x_1^2 + x_2^2 + x_3^2 = 1 \end{aligned}$$

Să se determine punctele KKT pentru această problemă. Care pereche de puncte îi va corespunde punctului de optim?

Problema 10. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} & \sum_{i=1}^n \log(c_i + x_i) \\ \text{s.l.: } & x \geq 0, \quad \sum_{i=1}^n x_i = 1, \end{aligned}$$

unde c_i reprezintă parametrii cunoscuți.

(i) Să se determine problema duală.

(ii) Să se determine un punct KKT.